Université Félix Houphouët-Boigny

UFR Mathématiques et Informatique

MÉMOIRE DE MASTER

Présenté devant

L'UNIVERSITÉ FÉLIX HOUPHOUËT-BOIGNY

Pour obtenir le grade de

Mention : Informatique

Spécialité : Data Sciences et Intelligence Artificielle

Par

SORO Doba Issiaka

TITRE DU MEMOIRE :

MODÉLISATION PRÉDICTIVE DES PERFORMANCES FINANCIÈRES DU PROGRAMME PEPT POUR L'AMÉLIORATION DU PROCESSUS DE TITRISATION DES CRÉANCES À ALC

Soutenance publique prévue le 15 juillet 2026

Le jury

Président : M. ADOU Kablan Jérôme, Professeur Titulaire, UFRMI, Université Félix Houphouët-Boigny

Directeur de mémoire : M. MAMADOU Diarra, Docteur-Maître de Conférences, UFRMI, Université Félix Houphouët-Boigny

Encadreur pédagogique : Mme. ASSE Brou Ida, Assistante, UFRMI, Université Félix Houphouët-Boigny

Examinateur : M. DABONE Yacouba, Data Scientist

Maitre de Stage : M. KOUAME Ruben, Data Scientist

Université Félix Houphouët-Boigny

UFR Mathématiques et Informatique

MÉMOIRE DE MASTER

Présenté devant

L'UNIVERSITÉ FÉLIX HOUPHOUËT-BOIGNY

Pour obtenir le grade de

Mention : Informatique

Spécialité : Data Sciences et Intelligence Artificielle

Par

SORO Doba Issiaka

TITRE DU MEMOIRE :

MODÉLISATION PRÉDICTIVE DES PERFORMANCES FINANCIÈRES DU PROGRAMME PEPT POUR L'AMÉLIORATION DU PROCESSUS DE TITRISATION DES CRÉANCES À ALC

Soutenance publique prévue le 15 juillet 2026

Le jury

Président : M. ADOU Kablan Jérôme, Professeur Titulaire, UFRMI, Université Félix Houphouët-Boigny

Directeur de mémoire : M. MAMADOU Diarra, Docteur-Maître de Conférences, UFRMI, Université Félix Houphouët-Boigny

Encadreur pédagogique : Mme. ASSE Brou Ida, Assistante, UFRMI, Université Félix Houphouët-Boigny

Examinateur : M. DABONE Yacouba, Data Scientist

Maitre de Stage : M. KOUAME Ruben, Data Scientist

DEDICACE

Je dédie ce travail

A mes parents, qui m'ont soutenu et encouragé pendant mes années d'études.

Leur soutien précieux mérite toute ma reconnaissance.

A mes frères et sœurs,

A mes amis.

REMERCIEMENTS

Avant toute chose, je rends grâce à Dieu, le Tout Miséricordieux et Très Miséricordieux, qui m'a accordé la santé, la volonté et la lucidité nécessaires pour mener ce travail à son terme. Que Sa bienveillance continue de m'accompagner sur chaque chemin que j'emprunterai.

Ce mémoire, je ne l'aurais jamais terminé seul. Derrière chaque page, il y'a des gens qui m'ont soutenu, corrigé, encouragé ou simplement cru en moi quand j'en avais besoin.

Je commence par L'**Université Félix Houphouët-Boigny d'Abidjan et l'Université de Rennes 2,** deux institutions que tout sépare géographiquement mais qui ont réussi quelque chose de rare : construire ensemble une formation qui tient vraiment la route. Ce que j'ai appris dans ce Master, je le dois à ce double ancrage. Merci au **Professeur BALLO ZIÉ**, Président de l'UFHB et au **Professeur Adou KABLAN**, Doyen de **l'UFR de Mathématiques et Informatique**.

Au **Professeur Adama COULIBALY**, je dois beaucoup. Il m'a suivi depuis ma licence à l'UNISAT et n'a jamais cessé de me pousser vers le haut. C'est le genre de professeur qu'on n'oublie pas. Merci **Dr. ASSIÉ Brou Ida** et **Dr. DIARRA Mamadou**, pour leur suivi rigoureux et leurs retours toujours utiles. Merci également aux membres du jury d'avoir pris le temps d'examiner ce travail.

Chez ALC, j'ai eu la chance de tomber sur des professionnels qui prennent le temps d'expliquer. Monsieur **GUI Olivier** m'a ouvert les portes de son département sans hésiter et m'a mis dans le bain dès le premier jour. Monsieur **KOUAME Ruben**, lui, a suivi ce projet de bout en bout avec une patience et une rigueur que j'admire vraiment. Ses remarques ont souvent changé ma façon de voir les choses.

À tous ceux que je n'ai pas cités mais qui savent ce qu'ils ont apporté, merci.

SOMMAIRE

DEDICACE 2

REMERCIEMENTS 3

SOMMAIRE 4

LISTE DES TABLEAUX 7

LISTE DES FIGURES 8

LISTE DES ABREVIATIONS ET SIGLES 9

AVANT-PROPOS 11

RESUME 12

ABSTRACT 13

INTRODUCTION GENERALE 14

PARTIE I : ENVIRONNEMENT DE TRAVAIL 15

CHAPITRE 1 : PRÉSENTATION DE LA STRUCTURE D'ACCUEIL 16

I. PRÉSENTATION DU GROUPE AFRICA LINK CAPITAL (ALC) 16

II. ALC TITRISATION : PREMIÈRE SOCIÉTÉ PRIVÉE DE GESTION DE FCTC EN UEMOA 17

III. POSITIONNEMENT STRATÉGIQUE ET RÔLE DANS LE FINANCEMENT DU DÉVELOPPEMENT 18

CHAPITRE 2 : PRÉSENTATION DU CAHIER DES CHARGES 19

I. CONTEXTE DU PROJET 19

II. OBJECTIF GÉNÉRAL 20

III. OBJECTIFS SPÉCIFIQUES 20

PARTIE II : DÉFINITION DES CONCEPTS 21

CHAPITRE 1 : LE PROGRAMME PEPT ET LA TITRISATION 22

I. FONCTIONNEMENT DU PROGRAMME PEPT 22

II. LA TITRISATION : DÉFINITION, PRINCIPES ET ENJEUX 23
III. LA TITRISATION DES FLUX FINANCIERS PEPT À ALC 25
IV. IMPORTANCE DE LA FIABILITÉ DES PAIEMENTS DANS LA TITRISATION 26
CHAPITRE 2 : CONCEPTS DE MACHINE LEARNING 27
I. DÉFINITIONS 27
II. LES TYPES D'APPRENTISSAGE EN MACHINE LEARNING 28
III. DESCRIPTION DES MODÈLES DE MACHINE LEARNING UTILISÉS 30
PARTIE III : METHODOLOGIE DE TRAVAIL 34
CHAPITRE 1 : COLLECTE ET DESCRIPTION DES DONNÉES 35
I. SOURCES DE DONNÉES 35
II. DESCRIPTION DES TABLES SOURCES 35
III. LOGIQUE MÉTIER DU PROGRAMME PEPT 38
CHAPITRE 2 : EXPLORATION ET PREPARATION DES DONNEES 40
I. EXPLORATION DES DONNÉES 40
II. FEATURE ENGINEERING 41
III. PRÉPARATION DES DONNÉES 43
IV. SÉLECTION DES VARIABLES 44
PARTIE IV : MODÉLISATION ET PRÉSENTATION DES RESULTATS 46
CHAPITRE 1 : CONSTRUCTION DU MODELE 47
I. TECHNIQUE DE PARTITIONNEMENT DE DONNEES 47
II. LES METRIQUES D'EVALUATION 49
CHAPITRE 2 : RESULTATS DES MODELES 52
I. PROBLEMATIQUE DE CLASSIFICATION 52
II. GESTION DU DESEQUILIBRE DES CLASSES 52
III. RESULTATS DES MODELES APRES RÉÉQUILIBRAGE 53

IV. COMPARAISON ET SELECTION DU MODELE OPTIMAL 56

CHAPITRE 3 : PRÉDICTIONS DU MODÈLE 57

I. SCORES INDIVIDUELS SUR 10 CLIENTS 57

II. INTERPRÉTATION DES RÉSULTATS 58

CONCLUSION 59

BIBLIOGRAPHIE ET WEBOGRAPHIE 61

ANNEXES 62

TABLE DES MATIERES 63

LISTE DES TABLEAUX

Tableau 1: Description des variables de la table COMPTEUR..... 35

Tableau 2: Description des variables de la table ACHATENERGIE 36

Tableau 3: Description des variables de la table REGLEMENT 37

Tableau 4: Régression logistique sans rééquilibrage des classes 52

Tableau 5: Résultats de la Régression Logistique après rééquilibrage 53

Tableau 6: Résultats du modèle Random Forest 54

Tableau 7:Résultats du modèle XGBoost..... 55

Tableau 8: Comparaison des performances des trois modèles sur le jeu de test 56

Tableau 9:Scores individuels XGBoost sur un echantillon de 10 clients PEPT 57

LISTE DES FIGURES

Figure 1:Organisation du Groupe Africa Link Capital 18

Figure 2: Schéma de l'opération de titrisation 26

Figure 3: Les différents types d'apprentissage 28

Figure 4:Schéma du fonctionnement de l'apprentissage supervisé 29

Figure 5: Algorithme de la régression logistique 30

Figure 6: Algorithme de l'arbre de décision 31

Figure 7: llustration Random Forest 32

Figure 8: Illustration Algorithme de Xgboost 33

Figure 9:La répartition entre les deux classes 41

Figure 10: Illustration de la validation croisée 48

Figure 11: Illustration des techniques de rééchantillonnages 48

Figure 12: Illustration de Matrice de confusion 50

Figure 13: Illustration d'une courbe ROC 51

Figure 14:Application de la règle métier sur kdb/q 62

Figure 15 : Aperçu des données 62

LISTE DES ABREVIATIONS ET SIGLES

Sigle / Abréviation	Signification
ALC	Africa Link Capital
AUC-ROC	Area Under the Curve — Receiver Operating Characteristic (Aire sous la courbe ROC)
CI-ENERGIES	Société des Energies de Côte d'Ivoire
CIE	Compagnie Ivoirienne d'Électricité
AMF-UMOA	Autorité des Marchés Financiers de l'Union Monétaire Ouest-Africaine
CSV	Comma-Separated Values (fichier de données tabulaires)
FCTC	Fonds Commun de Titrisation de Créances
F1	F1-Score (moyenne harmonique de la précision et du rappel)
IA	Intelligence Artificielle
KDB	Kdb+ (système de base de données orienté colonnes développé par KX Systems)
KPI	Key Performance Indicator (Indicateur Clé de Performance)
KWH	Kilowattheure (unité d'énergie électrique)
ML	Machine Learning (Apprentissage Automatique)
MLOps	Machine Learning Operations (pratiques de déploiement et de maintenance des modèles ML)
PEPT	Programme d'Électrification Pour Tous
PFE	Projet de Fin d'Études
PKL	Format de sérialisation Python (fichier .pkl, utilisé pour sauvegarder les modèles)
PND	Plan National de Développement
RF	Random Forest (Forêt Aléatoire)
RL	Régression Logistique

SMOTE	Synthetic Minority Over-sampling Technique (technique de rééchantillonnage)
UFHB	Université Félix Houphouët-Boigny
UEMOA	Union Économique et Monétaire Ouest-Africaine
XGBoost	eXtreme Gradient Boosting (algorithme de Machine Learning)

AVANT-PROPOS

La donnée est devenue, en l'espace de quelques années, l'un des actifs les plus stratégiques pour les organisations, qu'elles soient publiques ou privées. Sa capacité à révéler des tendances cachées, à anticiper des comportements et à éclairer la prise de décision en fait un levier incontournable dans un environnement économique de plus en plus complexe et compétitif. Face à cette réalité, la formation de professionnels capables de collecter, traiter et valoriser les données est devenue une priorité pour les institutions académiques du continent africain.

C'est dans cette logique que l'UFHB et l'Université de Rennes 2 en France ont décidé de travailler ensemble pour monter un Master en Data Science. Deux ans de formation, entre Abidjan et Rennes, avec des cours qui mélangent vraiment la théorie et la pratique. L'idée derrière tout ça est simple : former des gens capables de travailler sur des vrais problèmes de données dans le contexte africain, pas juste de réciter des formules.

Soucieux d'offrir à ses étudiants une expérience immersive au contact des réalités du terrain, le programme prévoit en fin de cycle un stage professionnel destiné à mettre à l'épreuve les acquis théoriques dans un contexte opérationnel réel. C'est dans ce cadre que nous avons eu le privilège d'être accueillis au sein d'Africa Link Capital (ALC), plus précisément au sein du département de la titrisation, pour une période de six mois, afin de travailler sur un projet de modélisation prédictive des performances financières du programme PEPT. Le présent mémoire constitue le rapport final de cette expérience.

RESUME

Ce travail de fin d'études raconte comment j'ai construit, pendant mon stage chez ALC, un modèle capable de prédire mois par mois si un abonné du Programme Electricité Pour Tous (PEPT) allait payer ou non. Derrière cette question technique se cache un enjeu financier concret : les redevances versées chaque mois par ces ménages à faibles revenus alimentent directement une opération de titrisation. Si les flux deviennent imprévisibles, c'est la confiance des investisseurs qui s'érode.

Pour répondre à cette question, j'ai travaillé sur les données des clients titrisés en 2024, suivis tout au long de 2025. Jeu de données consolidé dépasse 3,1 millions d'observations. Après un travail de feature engineering mené en R et en Python, j'ai construit 19 variables et comparé trois approches vu le volume des données : régression logistique, forêts aléatoires et XGBoost. C'est XGBoost qui s'est imposé comme le modèle le plus fiable, avec une accuracy de 82,7%, un AUC-ROC de 0,91 et un F1-score de 0,795. Appliqué au portefeuille actif, il a identifié 196 183 scorés comme susceptibles d'être en retard le mois suivant.

**Les résultats détaillés — matrices de confusion, courbes ROC et importance des variables — sont présentés dans la section Résultats et en annexe.*

ABSTRACT

This dissertation tells the story of how, during my internship at Africa Link Capital (ALC), I built a model capable of predicting month by month whether a subscriber of the Programme d'Électrification pour tous (PEPT) would pay or not. Behind this technical question lies a concrete financial challenge: the monthly fees paid by these low-income households, it is investor confidence that gradually erodes.

To tackle this question, i worked on data from clients securitized in 2024, tracked throughout 2025. The consolidated dataset exceeds 3.1 million observations. After a feature engineering process carried out in both R and Python, i built 19 variables and compared three approaches : Logistic Regression, Random Forest, and XGBoost. XGBoost emerged as the most reliable model, achieving an accuracy of 82.7%, an AUC-ROC of 0.91 and F1-score of 0.795. Applied to the active protfolio, it identified 196,183 clients out of 379,198 scored as likely to fall behind on payments the following month.

.

** The detailed results — confusion matrices, ROC curves and variable importance scores — are presented in the Results section and in the appendix.*

INTRODUCTION GENERALE

Dans un contexte mondial marqué par la montée en puissance de la donnée et l'essor des technologies d'intelligence artificielle, les institutions financières cherchent de plus en plus à s'appuyer sur des outils quantitatifs rigoureux pour sécuriser leurs opérations et optimiser leurs décisions. En Côte d'Ivoire, cette tendance se manifeste avec acuité dans le secteur de l'énergie, où le financement de l'accès à l'électricité pour les populations les plus vulnérables soulève des enjeux à la fois sociaux et financiers considérables.

Le Programme d'Électrification Pour Tous, communément appelé PEPT, c'est avant tout une réalité que j'ai pu observer de près durant mon stage cher ALC. Des centaines de milliers de ménages ivoiriens remboursent chaque mois leur branchement électrique via leur compteur prépayé. Au bout du compte, ces petits versements mis ensemble représentent des milliards de francs CFA qui circulent chaque mois dans le système. C'est précisément sur cette masse de flux réguliers qu'ALC a bâti son opération de titrisation : transformer ces créances en obligations vendues à des investisseurs sur le marché financier régional.

Mais voilà le problème concret que j'ai découvert en arrivant dans l'équipe : tout le monde sait que certains clients paient bien, d'autres mal, et d'autres pas du tout. Mais on ne savait pas lesquels, ni combien, ni quand. Les prévisions de flux se faisaient donc avec une part d'incertitude que les investisseurs n'apprécient guère. Un FCTC qui ne peut pas dire avec précision ce qu'il va encaisser le mois prochain, c'est un FCTC qui perd en crédibilité.

C'est de ce constant précis qu'est né ce projet, intitulé « **Modélisation prédictive des performance financières du programme PEPT pour l'amélioration du processus de titrisation des créances à ALC** ». L'idée était d'exploiter les données de paiement déjà disponibles pour construire un outil capable d'anticiper, mois après mois, le comportement de chaque client-et ainsi donner à ALC une vision plus claire et plus fiable de ses flux financiers à venir. Pour y parvenir, le travail s'articule autour de quatre grandes parties. La première présente le cadre dans lequel s'inscrit le projet. La deuxième pose les bases conceptuelles indispensables pour comprendre le fonctionnement du PEPT, ce que recouvre concrètement la titrisation, et les notions essentielles du Machine Learning. La troisième décrit la démarche méthodologique. Quant à la quatrième partie, c'est celle qui a mobilisé le plus d'énergie : on y construit les modèles, on identifie lequel est meilleur sur les données de test, et on applique le meilleur au portefeuille réel des abonnés PEPT.

PARTIE I : ENVIRONNEMENT DE TRAVAIL

Dans cette partie, il sera question de présenter la structure d'accueil, de présenter le projet ainsi que les objectifs à atteindre.

CHAPITRE 1 : PRÉSENTATION DE LA STRUCTURE D'ACCUEIL

I. PRÉSENTATION DU GROUPE AFRICA LINK CAPITAL (ALC)

Le Groupe Africa Link Capital, a débuté avec la Société Africa Link Capital communément désignée sous le sigle ALC, est une société de droit ivoirien fondée en mars 2006. Dès ses premières années d'existence, ALC s'est positionnée comme un cabinet de conseil financier et arrangeur indépendant, animé par une vocation affirmée de banque d'affaires au service des économies ouest-africaines.

Depuis sa création, le groupe a bâti une solide réputation dans plusieurs domaines de l'ingénierie financière : la restructuration financière, l'élaboration et la revue de plans d'affaires, les fusions-acquisitions, le financement de projets (project finance), les emprunts obligataires ainsi que le financement de besoin en fonds de roulement et d'investissements. À ce jour, le Groupe ALC a levé plus de 1 000 milliards de francs CFA auprès d'établissements financiers pour le compte d'entreprises, de banques et d'États parmi les plus dynamiques de la région ouest-africaine.

En 2012, face à l'évolution du paysage financier et à l'adoption par l'UEMOA d'un cadre réglementaire propice à la titrisation en 2010, les actionnaires du groupe ont procédé à une réorganisation stratégique. ALC Group, holding de participation, a été constitué pour chapeauter l'ensemble des activités, désormais regroupées en deux pôles distincts :

- **Le Pôle Banque d'Affaires**, en charge des activités de conseil financier ;
- **Le Pôle Titrisation**, composé de deux entités complémentaires : ALC Structuration, en charge de l'origination et de l'arrangement des opérations de titrisation, et ALC Titrisation, société de gestion des Fonds Communs de Titrisation de Créances (FCTC).

Le groupe a également obtenu pour sa société destinée à l'octroi de financement aux PME, ALC Microfinance, l'agrément en tant que Société du Système Financier Décentralisé (SFD) en octobre 2025.

II. ALC TITRISATION : PREMIÈRE SOCIÉTÉ PRIVÉE DE GESTION DE FCTC EN UEMOA

ALC Titrisation occupe une place pionnière dans le paysage financier de la zone UEMOA. Elle est la première société privée indépendante agréée par l'Autorité des Marché Financiers de l'UMOA (AMF-UMOA) pour exercer en tant que société de gestion de Fonds Communs de Titrisation de Créances. Cet agrément, obtenu à la suite de démarches initiées dès 2012 auprès du régulateur régional, lui confère une légitimité institutionnelle unique sur le marché.

La société dispose d'une plateforme technologique de haut niveau, utilisée par de grandes banques européennes et nord-américaines, capable de gérer plusieurs millions de créances par transaction. Cette infrastructure technique robuste constitue un avantage compétitif majeur, garantissant la fiabilité et la traçabilité des opérations sous gestion.

L'une des réalisations les plus significatives du groupe concerne la titrisation du Programme d'Électrification Pour Tous (PEPT), qui constitue une première dans la région ouest-africaine en matière d'obligation sociale adossée à des actifs. Cette opération, faite en deux compartiments d'un montant total de 120 milliards de francs CFA, a permis de mobiliser des financements importants destinés à améliorer l'accès à l'électricité, notamment au profit de plus de 1 600 000 ménages à faibles revenus. Sur le plan opérationnel, ALC Titrisation a pris en charge la gestion du véhicule d'émission, tandis qu'ALC Structuration a assuré le rôle d'arrangeur dans le cadre du placement obligataire.

III. POSITIONNEMENT STRATÉGIQUE ET RÔLE DANS LE FINANCEMENT DU DÉVELOPPEMENT

Au-delà de sa dimension commerciale, le Groupe ALC cherche à faire de la titrisation un véritable outil au service du financement du développement économique et social en Afrique de l'Ouest. En effet, en intervenant auprès des États, des entreprises privées ainsi que des institutions financières, le groupe participe activement à l'approfondissement du marché régional des capitaux.

C'est dans ce contexte stratégique que s'inscrit notre mission de stage. En travaillant au sein du département de la titrisation d'ALC, sous la supervision de Monsieur GUI Olivier, Directeur du département, et l'encadrement de Monsieur KOUAME Ruben, Data Scientiste, nous avons eu l'opportunité de contribuer concrètement à l'amélioration des outils de prévision financière utilisés dans le cadre de la gestion des créances PEPT titrisées.

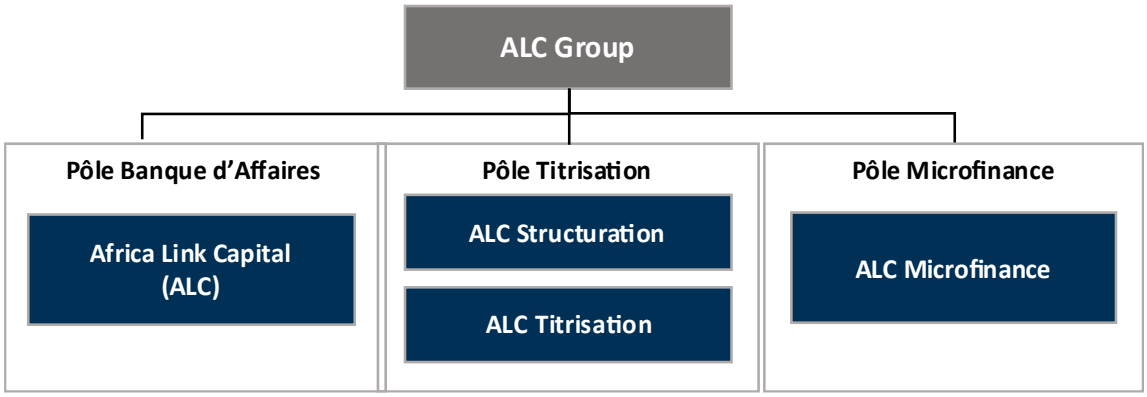


Figure 1:Organisation du Groupe Africa Link Capital

CHAPITRE 2 : PRÉSENTATION DU CAHIER DES CHARGES

I. CONTEXTE DU PROJET

Le Programme d'Électrification Pour Tous (PEPT) représente l'une des initiatives sociales les plus ambitieuses portées par l'État de Côte d'Ivoire depuis une décennie. À travers ce programme, des centaines de milliers de ménages à faibles revenus ont pu accéder à l'électricité grâce à un mécanisme de paiement progressif fondé sur des redevances mensuelles. Ces redevances, collectées chaque mois auprès d'un grand nombre de clients, constituent la principale source de financement de la structure de titrisation d'ALC

Dans ce cadre, ALC Titrisation assure la gestion du Fonds Commun de Titrisation de Créances (FCTC) adossé aux créances du programme PEPT, tandis qu'ALC Structuration intervient dans le suivi et la bonne exécution des opérations sur le marché obligataire. Ce montage financier repose sur une hypothèse essentielle, à savoir la régularité et la prévisibilité des paiements effectués par les bénéficiaires du programme.

L'analyse des données historiques révèle une réalité bien moins uniforme qu'on pourrait le croire. Les abonnés PEPT ne paient pas tous de la même façon : beaucoup respectent les échéances, mais d'autres accumulent les retards. Cette hétérogénéité complique les prévisions de flux et peut entamer la confiance des investisseurs.

Pendant ce stage, j'ai constaté que les équipes d'ALC passaient un temps considérable à analyser ce qui s'était déjà passé, sans vraiment disposer d'un outil pour regarder devant, les analyses étaient faites après les faits, les modèles financiers construits à la main, et quand un client commençait à décrocher, on le découvrait souvent trop tard. Cette réalité m'a frappé, parce qu'elle crée une vraie vulnérabilité.

L'idée de ce projet est donc partie de là. Construire un modèle de ML capable de dire, mois par mois et client par client, celui-là risque de ne pas payer avec un score, c'est donner aux équipes d'ALC le temps de réagir avant que le problème ne se pose, et sécuriser ainsi le processus de titrisation.

II. OBJECTIF GÉNÉRAL

L'objectif principal de ce projet est de concevoir et de déployer un modèle de machine learning permettant de prévoir, sur une base mensuelle, le comportement de paiement des clients du programme PEPT. Plus précisément, il s'agit de classer chaque abonné en deux catégories : « à jour », lorsque le montant de la redevance payée est conforme à l'obligation mensuelle, et « en retard » dans le cas contraire. Cette approche vise à fournir à Africa Link Capital (ALC), dès le début de chaque mois, une estimation fiable des flux de paiements attendus ainsi que des risques de défaut associés au portefeuille PEPT.

III. OBJECTIFS SPÉCIFIQUES

Pour atteindre cet objectif général, le projet se décline en plusieurs axes de travail complémentaires :

- **Construire le pipline de données :** à chaque début de mois, il faut pouvoir extraire les données, les nettoyer et assembler automatiquement pour avoir un dataset exploitable sans perdre du temps à tout refaire manuellement.
- **Définition d'un indicateur de performance financière :** avant de modéliser quoi que ce soit, il fallait poser une règle claire. Un client est à jour s'il a versé au moins le montant de sa redevance normative mensuelle. Sinon, il est en retard. Simple, mais cette définition a été le socle de tout le reste.
- **Construction de plusieurs modèles :** plusieurs algorithmes de classification ont été expérimentés afin d'identifier celui qui présente les meilleures performances selon les métriques retenues.
- **Validation sur le jeu de données test** : un bon modèle ne doit pas seulement bien fonctionner sur les données qu'il a déjà vues. Nous avons donc mis de côté une partie des données dès le début, sans jamais les utiliser pendant l'entraînement, pour tester le modèle dans des conditions proches de la réalité. C'est ce test qui nous a permis de savoir si le modèle apprenait vraiment ou s'il se contentait de mémoriser.
- **Produire les prédictions** : une fois le modèle validé, nous l'avons appliqué à l'ensemble des clients actifs du portefeuille PEPET.

PARTIE II : DÉFINITION DES CONCEPTS

La conduite de ce projet mobilise un ensemble de notions issues de domaines variés, allant de la finance structurée à l'apprentissage automatique. Cette partie a pour vocation d'en poser les fondements conceptuels, afin de faciliter la compréhension de la démarche méthodologique développée dans les parties suivantes.

CHAPITRE 1 : LE PROGRAMME PEPT ET LA TITRISATION

I. FONCTIONNEMENT DU PROGRAMME PEPT

Le Programme d'Électrification Pour Tous, désigné par l'acronyme PEPT, trouve son origine dans la volonté de l'État de Côte d'Ivoire de réduire les inégalités d'accès à l'électricité. Le PEPT est né d'un constat simple : beaucoup de familles ivoiriennes, surtout dans les quartiers périurbains et les villages, n'ont pas les moyens de payer d'un coup les frais de branchement électrique. Le gouvernement a donc décidé, dans le cadre du PND 2014-2025, de leur permettre de rembourser progressivement, sur plusieurs années.

Concrètement, voilà comment ça marche. Quand un ménage rejoint le programme, il ne paie pas tout de suite l'intégralité de son branchement. À la place, chaque mois, une petite somme lui est demandée, c'est ce qu'on appelle la redevance mensuelle normative. Son montant dépend du type d'offre choisi et de la durée de remboursement, qui peut aller jusqu'à dix ans.

Le dispositif repose principalement sur un mécanisme de collecte automatique. Lorsqu'un client recharge son compteur prépayé, une partie du montant est directement affectée au remboursement du coût de raccordement, avant que le solde restant ne soit converti en consommation d'électricité.

Ainsi, la combinaison des prélèvements automatiques sur les recharges et des paiements directs permet d'alimenter régulièrement les flux financiers du programme PEPT.

Le suivi de ces flux est assuré conjointement par la Compagnie Ivoirienne d'Électricité (CIE), opérateur technique du programme, et CI-ENERGIES, établissement public en charge de la gestion du patrimoine énergétique national. Les données de paiement sont centralisées dans un système d'information structuré autour de plusieurs tables relationnelles ACHATENERGIE, REGLEMENT, COMPTEUR dont l'exploitation constitue le point de départ de notre projet de modélisation.

II. LA TITRISATION : DÉFINITION, PRINCIPES ET ENJEUX

1. Définition

La titrisation est une technique financière qui permet à une entité, publique ou privée, de mobiliser des fonds en adossant une émission de titres à un portefeuille de créances qu'elle détient. Ces actifs, généralement illiquides par nature, sont ainsi transformés en instruments négociables sur le marché financier —le plus souvent des obligations — offrant des maturités variées selon les besoins des émetteurs et les attentes des investisseurs.

Ce qui m'a frappé en arrivant chez ALC, c'est la logique juridique derrière la titrisation. Quand une entreprise veut titriser ses créances, elle ne les garde pas dans ses livres. Elle les transfère à une entité séparée qu'on appelle le Fonds Commun de Titrisation de Créances, le FCTC. Ce fonds devient alors le propriétaire légal des créances et c'est lui qui émet les obligations sur le marché. Les investisseurs qui achètent ces obligations seront remboursés grâce aux flux générés par les créances, dans notre cas les redevances PEPT.

Ce qui est important dans ce montage, c'est la séparation entre l'entreprise qui cède les créances et le FCTC. Si demain l'entreprise cédante rencontre des difficultés financières, les créances logées dans le FCTC ne sont pas touchées. Les investisseurs sont ainsi protégés des risques propres à l'entité cédante. C'est cette isolation juridique qui donne à la titrisation toute sa crédibilité aux yeux du marché.

2. Principes généraux

Une opération de titrisation, ça se construit étape par étape. D'abord, celui qui veut titriser une banque, une entreprise ou un État, fait le tri dans ses créances. Il sélectionne celles qui se ressemblent en termes de risque et de rendement, celles qui vont convaincre le marché. Une fois ce portefeuille constitué, il le cède au FCTC qui en devient le seul propriétaire.

Le FCTC émet ensuite des obligations sur le marché, organisées en plusieurs tranches selon leur niveau de risque et leur ordre de remboursement. Les tranches seniors sont remboursées en premier : moins exposées, elles affichent généralement de meilleures notations et attirent naturellement les investisseurs institutionnels. Les tranches subordonnées, en revanche, supportent un risque plus élevé du fait de leur rang inférieur, mais elles compensent cela par des rendements plus attractifs.

Dans le cas du PEPT, c'est exactement ce schéma qui a été retenu, avec trois tranches d'obligations placées sur le marché régional de l'UEMOA.

Dans ce dispositif, ALC Titrisation occupe une position centrale. C'est elle qui, au quotidien, assure le lien entre les flux de paiement collectés et les investisseurs qui attendent leurs remboursements.

3. Intérêt de la titrisation pour les différentes parties prenantes

Ce qui m'a aidé à comprendre la titrisation en profondeur, c'est de regarder ce que chaque acteur y gagne concrètement.

Pour **le cédant,** qu'il s'agisse d'une banque ou d'une entreprise, la titrisation constitue un mécanisme permettant de générer rapidement des liquidités par le transfert de ses créances au FCTC, sans attendre leur remboursement progressif. Dans le cas des établissements bancaires, cette opération présente également un intérêt réglementaire, dans la mesure où elle contribue à alléger les exigences en fonds propres.

Pour une entreprise telle que la CIE, dans le cadre du programme PEPT, l'intérêt est comparable. La titrisation permet de mobiliser immédiatement des ressources financières, plutôt que d'attendre l'encaissement progressif des paiements des abonnés, facilitant ainsi le financement de l'extension du programme à de nouveaux ménages. Elle permet également un partage du risque avec les investisseurs.

Du point de vue des investisseurs, ces instruments représentent une opportunité de placement adossée à des actifs réels, générant des flux de trésorerie réguliers et traçables. Selon la tranche choisie, ils peuvent ajuster leur niveau de risque ainsi que le rendement attendu, ce qui en fait une alternative intéressante aux obligations classiques.

III. LA TITRISATION DES FLUX FINANCIERS PEPT À ALC

Dans le cadre du programme PEPT, ALC a structuré une opération de titrisation adossée aux redevances mensuelles versées par les abonnés. Le portefeuille de créances sous-jacent est constitué des droits à recevoir les flux de paiement de plusieurs centaines de milliers de clients répartis sur l'ensemble du territoire ivoirien. Ces créances, issues de contrats d'une durée initiale pouvant atteindre dix ans, génèrent des flux mensuels dont la régularité est la condition sine qua non de la viabilité de l'opération.

ALC Structuration est intervenue en qualité d'arrangeur de l'opération. À ce titre, elle a assuré la conception de la structure financière.

De son côté, ALC Titrisation a la charge de la gestion courante du FCTC. Elle assure notamment le suivi des encaissements, le calcul des paiements dus aux investisseurs, ainsi que la production des rapports périodiques destinés au régulateur et aux porteurs de titres.

Ce qui m'a particulièrement marqué en travaillant chez ALC, c'est de réaliser que l'opération sur laquelle je travaillais n'était pas banale. Les 60 milliards de francs CFA levés grâce à cette titrisation ont permis de raccorder de nouveaux ménages au réseau électrique, des familles qui n'auraient pas pu se payer un branchement classique. Mais au-delà de l'aspect social, cette opération a aussi été une première dans toute la zone UEMOA : jamais une obligation sociale adossée à des actifs n'avait été émise dans la région avant ça. C'est Euromoney qui le souligne dans un article de 2022 consacré au développement de la titrisation en Afrique de l'Ouest, en citant directement Monsieur GUI Olivier, Directeur Général d'ALC Titrisation, pour décrire l'évolution du marché ces dernières années.

IV. IMPORTANCE DE LA FIABILITÉ DES PAIEMENTS DANS LA TITRISATION

Dès les premières semaines chez ALC, une évidence s'est imposée : dans une titrisation, tout repose sur la régularité des paiements. Les investisseurs ont accepté de mettre de l'argent sur la table parce qu'on leur a promis des remboursements. Tant que les abonnés paient, la promesse tient. Mais quand les retards s'accumulent, les flux réels s'écartent des projections, et le FCTC peut se retrouver en difficulté pour honorer ses engagements.

En analysant les données, on remarque que le comportement de paiement des clients est change d'un client à l'autre. Certains paient chaque mois sans exception, presque comme une habitude.

D'autres encore accumulent les retards mois après mois sans jamais vraiment rattraper. Cette diversité de comportements rend les projections de flux très difficiles à établir avec précision, surtout quand on gère un portefeuille de plusieurs centaines de milliers de clients.

C'est là que le machine Learning prend ici toute son importance. La capacité à identifier, chaque mois, les clients susceptibles d'être en retard permet d'améliorer l'estimation des encaissements réels du FCTC. Sur cette base, ALC peut mieux piloter ses réserves, renforcer la qualité de l'information transmise aux investisseurs et améliorer la crédibilité globale des opérations de titrisation.

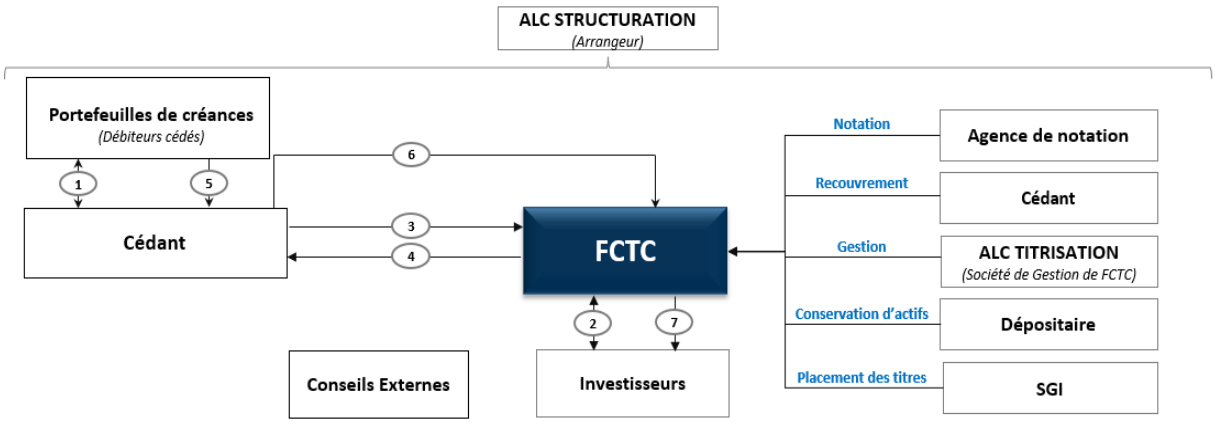


Figure 2: Schéma d'une opération de titrisation

CHAPITRE 2 : CONCEPTS DE MACHINE LEARNING

I. DÉFINITIONS

1. Intelligence Artificielle

L'Intelligence Artificielle (IA) désigne l'ensemble des techniques et méthodes informatiques visant à concevoir des systèmes capables de reproduire, d'imiter ou de dépasser certaines facultés cognitives humaines. Résoudre des problèmes complexes, reconnaître des formes, comprendre un langage naturel, prendre des décisions dans des environnements incertains : autant de capacités que l'IA cherche à conférer aux machines. Depuis les premières formalisations théoriques des années 1950, le champ de l'IA n'a cessé de s'élargir, porté par l'explosion des volumes de données disponibles et la démocratisation des ressources de calcul.

Aujourd'hui, l'intelligence artificielle s'impose comme une technologie présente dans de nombreux domaines, notamment la santé, la finance, l'industrie et l'énergie. Dans notre contexte, elle constitue le cadre méthodologique sur lequel repose la démarche de modélisation adoptée.

2. Machine Learning

Le Machine Learning (ML), c'est la partie de l'Intelligence Artificielle qui m'a le plus intéressé depuis le début de ma formation. L'idée de base est simple mais puissante : plutôt que d'écrire des règles à la main pour dire à un programme quoi faire, on lui donne des données et on le laisse trouver les règles tout seul. C'est exactement l'inverse de la programmation classique.

Dans le cadre de ce projet, c'est précisément ce type d'approche qui s'imposait. Le comportement de paiement d'un abonné PEPT dépend d'une multitude de facteurs simultanés (historique de recharge, zone géographique, type d'offre, période de l'année) qu'il aurait été illusoire de vouloir capturer manuellement.

II. LES TYPES D'APPRENTISSAGE EN MACHINE LEARNING

Le Machine Learning regroupe plusieurs familles d'approches, distinguées principalement par la nature des données utilisées lors de la phase d'entraînement et par la manière dont le modèle reçoit ou non un retour sur ses prédictions. On en identifie généralement quatre grandes catégories.

- **Apprentissage supervisé :** les données d'apprentissage sont constituées de données d'entrée et d'une valeur cible correspondante. Les cas où la variable cible fait partie d'un nombre fini de catégories discrètes sont appelés tâches de classification ;

- **Apprentissage non supervisé :** les données d'apprentissage ne sont constituées que de données d'entrée. Le clustering est un exemple dans lequel l'objectif est de découvrir des groupes ou des exemples similaires dans les données ;

- **Apprentissage par renforcement :** c'est une méthode qui consiste à laisser un algorithme apprendre de ses erreurs pour atteindre un objectif. L'algorithme essayera de nombreuses approches différentes pour tenter d'atteindre son but. En fonction de ses performances, il sera récompensé ou pénalisé pour l'inciter à poursuivre dans une voie ou à changer d'approche. Cette technique notamment utilisée pour permettre à une Intelligence Artificielle de surpasser les humains dans les yeux.

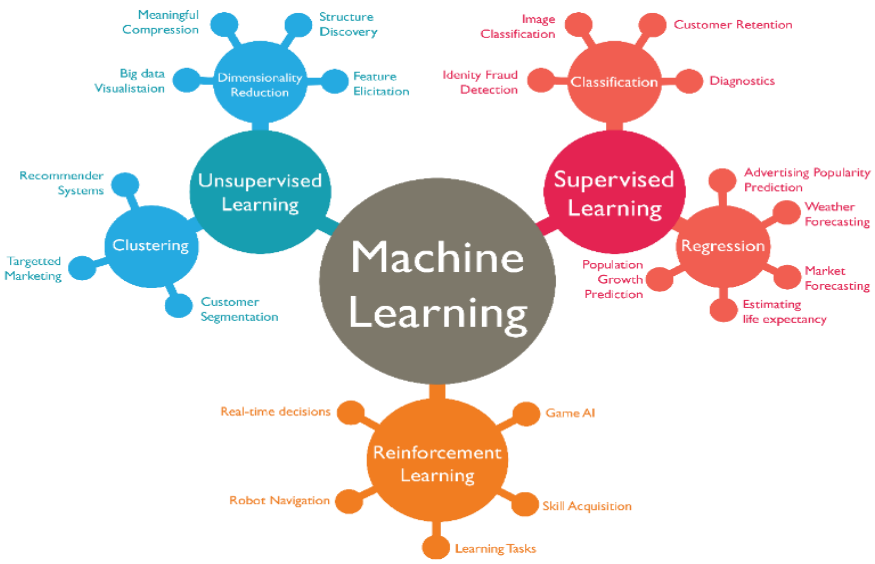


Figure 4: Les différents types d'apprentissage

Focus : L'apprentissage supervisé

L'apprentissage supervisé repose sur l'utilisation d'une vérité terrain : on dispose d'une connaissance préalable des valeurs de sortie associées à chaque échantillon. L'objectif est d'apprendre une fonction qui, à partir d'un ensemble de données étiquetées, se rapproche au mieux de la relation existant entre les entrées et les sorties observables. Formellement, à partir d'un échantillon d'apprentissage $\mathbf{D_n = \{(x_1, y_1), \ldots, (x_n, y_n)\}}$, il s'agit d'inférer la relation entre x et y, où $x = (x_1, \ldots, x_n)$ représente le vecteur des caractéristiques (données d'entrée) et $y = (y_1, \ldots, y_n)$ celui des étiquettes ou labels (données de sortie).

Dans le cadre de ce projet, nous nous inscrivons pleinement dans ce paradigme. Chaque observation correspond à un **couple client-mois**, décrit par un ensemble de variables comportementales, de consommation et contractuelles. L'algorithme est ainsi exposé à un historique d'exemples étiquetés, à partir duquel il apprend à associer des configurations de variables d'entrée à une variable de sortie. Une fois l'entraînement achevé, le modèle est capable de produire des prédictions pour des observations nouvelles qu'il n'a jamais rencontrées.

Il existe deux approches d'apprentissage supervisé selon la nature de ce qu'on cherche à prédire :

- $y \subset \mathbb{R}$: la valeur à prédire est un nombre continu, on parle de régression.
- $y = 1, \ldots, K$: lorsque l'ensemble des valeurs de sortie est fini, il s'agit d'un **problème de classification**, cela consiste à mapper chaque entrée à une classe. La fonction de prédiction est appelée *classificateur*.

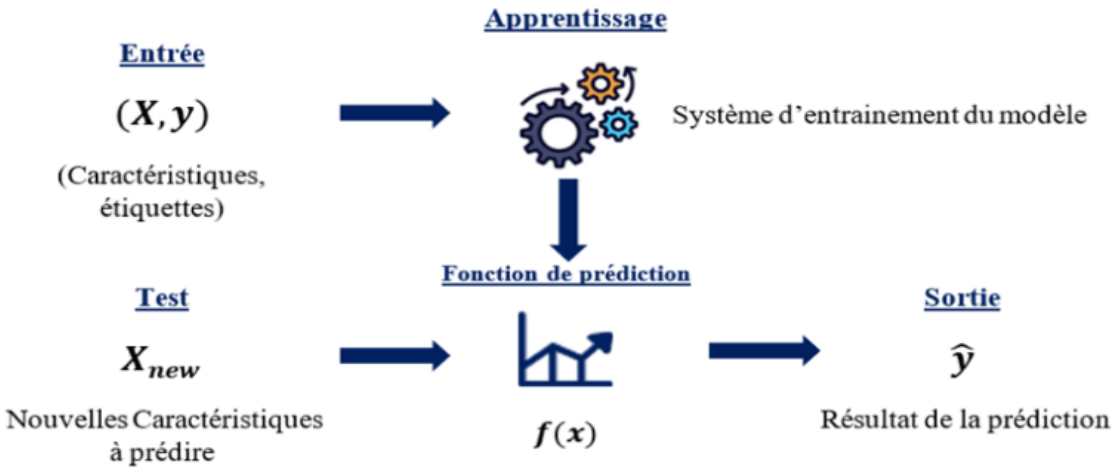


Figure 5:Schéma du fonctionnement de l'apprentissage supervisé

III. DESCRIPTION DES MODÈLES DE MACHINE LEARNING UTILISÉS

Il existe plusieurs techniques d'apprentissages automatiques supervisés. Cependant nous en présenterons quelques-unes :

1. La Régression Logistique

La régression logistique est l'un des algorithmes de classification les plus anciens et les plus utilisés en apprentissage automatique. Malgré sa dénomination, il s'agit bien d'un modèle de classification et non de régression : son objectif est d'estimer la probabilité qu'une observation appartienne à l'une des classes d'une variable cible binaire.

Son fonctionnement repose sur l'application de la fonction sigmoïde à une combinaison linéaire des variables d'entrée. Cette transformation garantit que la valeur produite est toujours comprise entre 0 et 1, et donc interprétable comme une probabilité. Un seuil de décision, généralement fixé à 0,5, permet ensuite de convertir cette probabilité en une classe prédite.

Sur la figure ci-dessous, nous présentons une illustration de la régression logistique binaire.

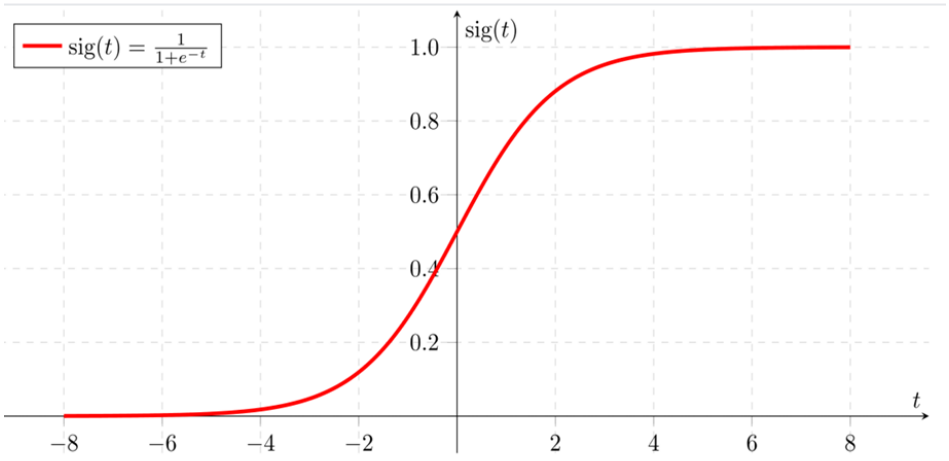


Figure 6: Algorithme de la régression logistique

2. Les Arbres de Décision

Un arbre de décision (AD) est un outil d'exploration des données et d'aide à la décision représentant un ensemble de choix sous la forme graphique d'un arbre. L'ensemble des nœuds se divise en trois catégories :

- Nœuds racine : l'accès à l'arbre se fait par ce nœud ;
- Nœuds internes : nœuds ayant des descendants (ou enfants) qui sont à leur tour des nœuds ;
- Nœuds terminaux (ou feuilles) : nœuds qui n'ont pas de descendants. Il existe deux principaux types d'arbre de décision :
- Les arbres de régressions permettent de prédire une quantité réelle, une valeur numérique.
- Les arbres de classification permettent de prédire à quelle classe la variable de sortie appartient.

L'idée derrière l'AD dans l'analyse du comportement est de fournir une classification entre deux classes « En retard » et « A jour » de la redevance. Il commence par un nœud racine qui contient les deux types de classe.

En général, la sélection de la variable est basée sur la pureté de la division, où plusieurs approches sont disponibles pour la division où la plus courante utilisée est l'entropie de l'information, qui est basée sur l'information la plus élevée. Après avoir fini de construire l'AD, certaines sections de l'arbre avec moins de capacité prédictive peuvent être supprimées ou élaguées. Cela peut réduire la complexité de l'arbre, obtenant ainsi une meilleure précision en réduisant le surajustement.

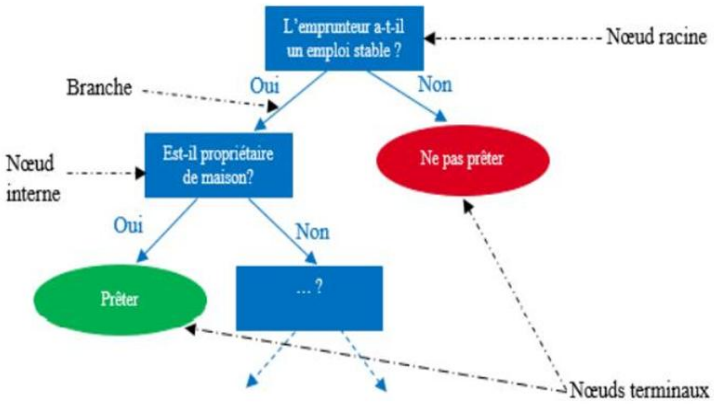


Figure 7: Algorithme de l'arbre de décision

3. Les Forêts Aléatoires (ou Random Forest en Anglais)

Les forêts aléatoires sont des méthodes qui permettent d'obtenir des modèles prédictifs pour la classification et la régression. La méthode met en œuvre des arbres de décision binaire, notamment des arbres CART proposés par Breiman et al. (1984). La prédiction finale est obtenue par agrégation des résultats individuels de chaque arbre : dans un problème de classification, c'est la classe majoritairement prédite par l'ensemble des arbres qui est retenue. L'idée générale derrière la méthode est la suivante : au lieu d'essayer d'obtenir une méthode optimisée en une fois, on génère plusieurs prédicteurs avant de mettre en commun leurs différentes prédictions.

Les forêts aléatoires présentent également l'avantage de fournir une mesure naturelle de l'importance des variables, ce qui facilite l'interprétation des résultats et la sélection des features les plus discriminantes pour la prédiction du comportement de paiement.

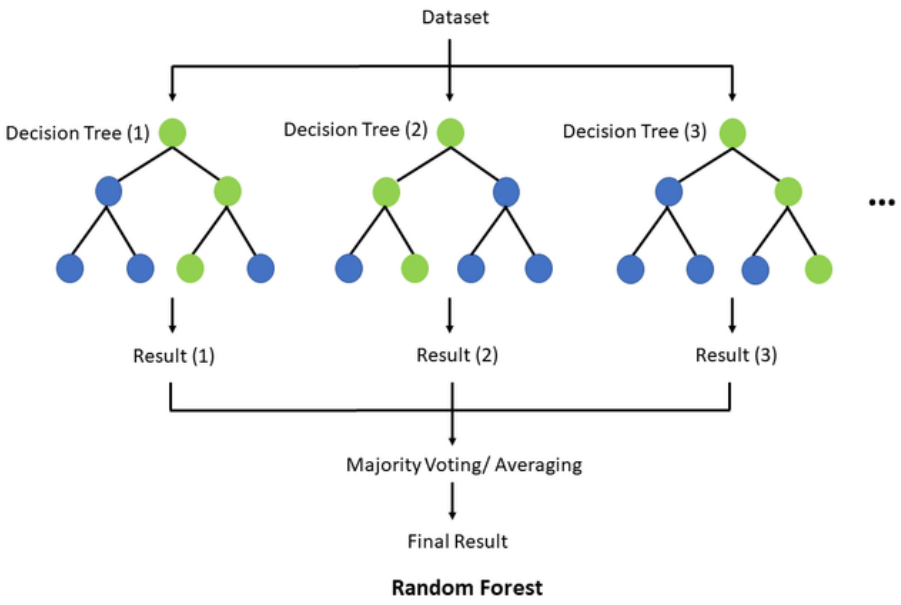


Figure 8: llustration Random Forest

4. Le Gradient Boosting et XGBoost

4.1. Principe du Gradient Boosting

Le Gradient Boosting est une technique d'ensemble learning dont le principe diffère de celui du Random Forest. Contrairement à ce dernier, qui construit des arbres indépendants en parallèle, le Gradient Boosting repose sur une approche séquentielle où chaque nouvel arbre est entraîné pour corriger les erreurs des modèles précédents. Cette méthode permet une amélioration progressive des performances, chaque itération se concentrant sur les observations mal classées lors des étapes précédentes. Le modèle accorde ainsi davantage d'attention aux cas difficiles, ce qui améliore sa capacité de généralisation.

4.2. XGBoost

XGBoost, qui signifie eXtreme Gradient Boosting, est une bibliothèque logicielle open source qui fournit un cadre pour le gradient boosting, une technique d'apprentissage automatique populaire. XGBoost est une implémentation des arbres de décision de Gradient Boosting. Il a été largement utilisé et a gagné en popularité en raison de sa dominance dans de nombreuses compétitions de machine learning. Dans cet algorithme, les arbres de décision sont créés de manière séquentielle. Les poids sont attribués à toutes les variables indépendantes qui sont ensuite introduites dans l'arbre de décision qui prédit les résultats. Le poids des variables prédites de manière incorrecte par l'arbre est augmenté et ces variables sont ensuite introduites dans le deuxième arbre de décision. Ces classificateurs individuels s'associent ensuite pour donner un modèle fort et plus précis.

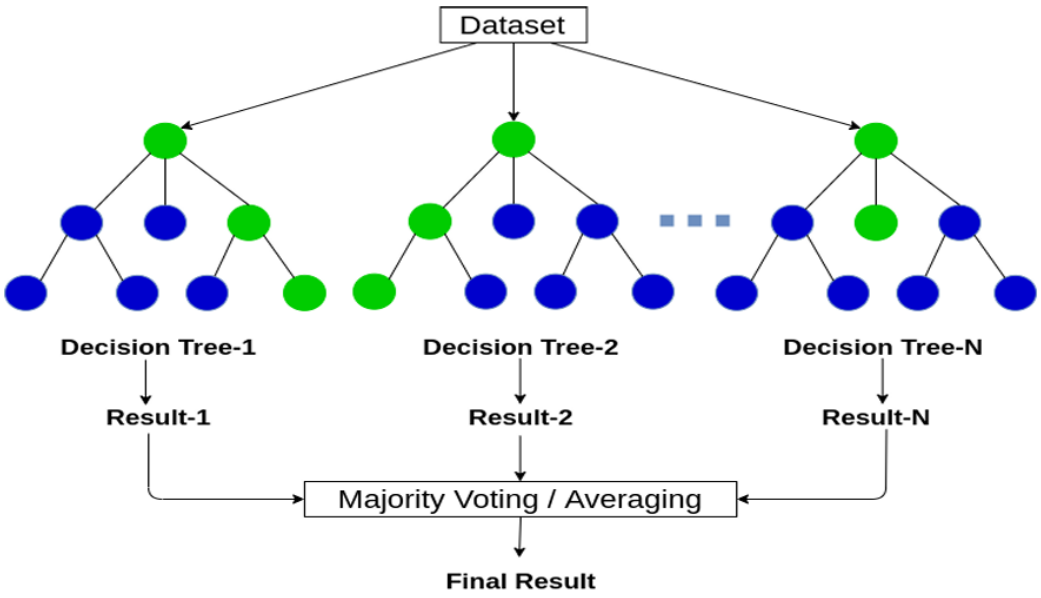


Figure 9: Illustration Algorithme de Xgboost

PARTIE III : METHODOLOGIE DE TRAVAIL

Cette partie décrit notre cadre méthodologique, depuis la construction du pipeline de données jusqu'au feature engineering.

CHAPITRE 1 : COLLECTE ET DESCRIPTION DES DONNÉES

I. SOURCES DE DONNÉES

Les données utilisées dans ce projet proviennent du système d'information d'ALC. Elles sont stockées dans une base de données KDB+, reconnue pour sa capacité à gérer de grands volumes de données temporelles. Trois tables principales ont été exploitées : **COMPTEUR**, **ACHATENERGIE** et **REGLEMENT**.

Les extractions ont été réalisées en langage **q**, le langage associé à KDB+. En combinant les informations issues de ces différentes tables, il a été possible de reconstituer, pour chaque client et pour chaque mois, son comportement de paiement. Cette vision détaillée dans le temps a ensuite servi de base pour la phase de modélisation.

II. DESCRIPTION DES TABLES SOURCES

1. Table COMPTEUR

La table **COMPTEUR** regroupe les informations descriptives des clients, notamment le type d'offre souscrite, la région de rattachement ainsi que le montant de la redevance mensuelle. Dans ce projet, elle sert de base de référence pour l'année 2024 afin d'identifier les clients éligibles, puis de les croiser avec les autres tables.

Tableau 1: Description des variables de la table COMPTEUR

Variable	Type	Description
Reference	Chaîne	Identifiant unique du client PEPT
Compteur	Numérique	Numéro de série du compteur prépayé
OffreId	Chaîne	Code de l'offre tarifaire souscrite
RegionId	Chaîne	Région géographique du client
DirectionId	Chaîne	Direction commerciale de rattachement

RedevanceMensuelleNormative	Numérique	Montant mensuel contractuel dû en FCFA
MaturiteInitialeAnnee	Numérique	Durée initiale du contrat en années
Annee	Numérique	Année de référence du contrat

2. Table ACHATENERGIE

La table ACHATENERGIE enregistre l'ensemble des opérations de rechargement effectuées par les clients PEPT, agrégées au niveau mensuel par client. Elle constitue la principale source d'information sur le comportement de consommation et sur le mécanisme de ponction automatique, qui représente le mode de remboursement le plus répandu dans le programme.

Tableau 2: Description des variables de la table ACHATENERGIE

Variable	Type	Description
Reference	Chaîne	Identifiant unique du client
Mois	Numérique	Mois de la transaction (1 à 12)
Annee	Numérique	Année de la transaction
NombreRechargement	Numérique	Nombre total de rechargements effectués
KwhAchete	Numérique	Quantité d'énergie achetée en kWh
Ponction	Numérique	Montant prélevé automatiquement sur les recharges au titre du remboursement PEPT en FCFA
MontantEnergie	Numérique	Montant affecté à la consommation d'énergie en FCFA

PrimeFixe	Numérique	Part fixe prélevée à chaque rechargement en FCFA
MontantRecharge	Numérique	Montant total rechargé par le client en FCFA

3. Table REGLEMENT

La table REGLEMENT enregistre les redevances effectivement encaissées par la CIE au titre du programme PEPT, ventilées selon le mode de paiement. Elle distingue les encaissements réalisés automatiquement via les achats d'énergie de ceux effectués par paiement direct de branchement. Cette table est essentielle pour reconstituer le montant total réellement versé par chaque client au cours d'un mois donné.

Tableau 3: Description des variables de la table REGLEMENT

Variable	Type	Description
Reference	Chaîne	Identifiant unique du client
Mois	Numérique	Mois du règlement
Annee	Numérique	Année du règlement
RedevanceviaAchatenergieFCFA	Numérique	Redevance encaissée via les achats d'énergie par ponction automatique en FCFA
RedevancebranchementuniquementFCFA	Numérique	Redevance encaissée par paiement direct de branchement hors achat d'énergie en FCFA

III. LOGIQUE MÉTIER DU PROGRAMME PEPT

1. La redevance mensuelle normative

La redevance mensuelle normative représente le montant contractuellement dû par chaque client PEPT au cours d'un mois donné. Elle est fixée à la souscription du contrat et dépend de l'offre tarifaire choisie et de la durée initiale de remboursement. Ce montant constitue le seuil de référence par rapport auquel le comportement de paiement de chaque client est évalué chaque mois.

2. Les modes de recouvrement

Un client peut rembourser sa redevance de deux manières. Le cas le plus fréquent est la ponction automatique. Concrètement, lorsqu'un abonné recharge son compteur à prépaiement, une partie de la somme est directement prélevée pour rembourser son branchement, sans qu'il ait à faire quoi que ce soit de particulier. La plupart du temps, il ne s'en rend même pas compte. Dans les données, ce montant apparait sous la variable ponction dans la table ACHATENERGIE.

Mais certains clients ne rechargent pas assez pour couvrir leur redevance mensuelle par ce seul canal. Pour eux, il existe un deuxième mode : le paiement direct de branchement, effectué séparément, en dehors de tout achat d'énergie. Ce montant est enregistré dans la variable RedevancebranchementuniquementFCFA de la table REGLEMENT.

Dans mon travail, j'ai additionné ces deux composantes pour obtenir ce que j'ai appelé la redevance_paye, c'est-à-dire ce que le client a réellement versé au titre du PEPT sur le mois considéré.

3. Calcul de la redevance payée et définition du target

La redevance effectivement payée par un client au cours d'un mois donné est calculée en additionnant les deux sources de recouvrement identifiées ci-dessus. Cette variable, notée redevance_paye, est définie comme suit :

```
redevance_paye = Ponction + RedevancebranchementuniquementFCFA
```

À partir de cette variable, la variable cible binaire du modèle, notée target_mois, est construite par comparaison avec la redevance mensuelle normative :

```
target_mois = À_jour si redevance_paye ≥ RedevanceMensuelleNormative
target_mois = En_retard sinon
```

Cette définition binaire est directement alignée sur les besoins opérationnels d'ALC : un client est considéré comme à jour dès lors qu'il a couvert l'intégralité de son obligation mensuelle, quelle que soit la combinaison de modes de paiement utilisée.

CHAPITRE 2 : EXPLORATION ET PREPARATION DES DONNEES

Avant d'engager la phase de modélisation, il est indispensable de procéder à une analyse approfondie des données disponibles et à leur mise en forme. Ce chapitre couvre successivement l'exploration statistique du dataset, les opérations de nettoyage et de préparation des données, puis le feature engineering réalisé pour enrichir le jeu de variables en vue de la construction du modèle prédictif.

I. EXPLORATION DES DONNÉES

1. Structure générale du dataset

Une fois les différentes tables extraites et combinées, le dataset obtenu est structuré de manière simple : une ligne par client et par mois. Chaque observation regroupe l'ensemble des informations relatives au client sur un mois donné, notamment les recharges, les paiements et la consommation. Il s'agit donc d'une vue mensuelle du comportement de chaque client.

Les variables disponibles se répartissent en trois grandes catégories : les variables issues de la table COMPTEUR, qui décrivent le profil contractuel et géographique du client, les variables issues de la table ACHATENERGIE, qui renseignent sur les comportements de rechargement et de consommation, et les variables issues de la table REGLEMENT, qui capturent les paiements effectués directement au titre de la redevance. À ces variables brutes s'ajoute la variable calculée redevance_paye, dont la construction a été décrite dans le chapitre précédent.

2. Distribution de la variable cible

L'analyse de la distribution de la variable cible constitue une étape préalable indispensable, car elle conditionne directement les choix méthodologiques à opérer lors de la modélisation. Sur l'ensemble du dataset d'entraînement, la répartition entre les deux classes se présente comme suit :

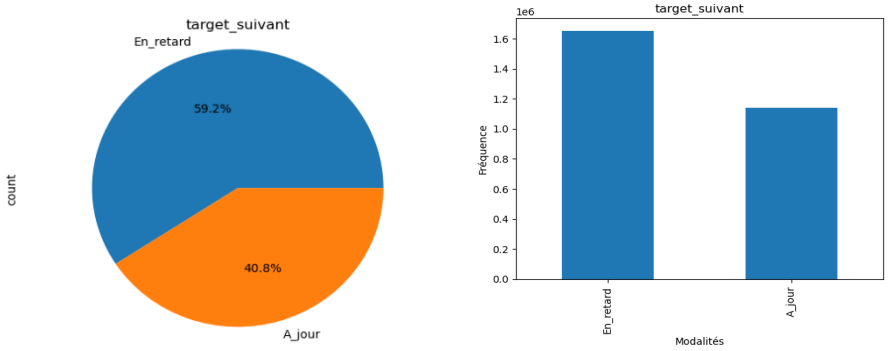


Figure 10:La répartition entre les deux classes

II. FEATURE ENGINEERING

Le feature engineering désigne l'ensemble des opérations de transformation et de création de nouvelles variables à partir des données brutes, dans le but d'enrichir le pouvoir explicatif du modèle. Dans notre projet, cette étape a été réalisée en deux temps : une première phase en R, qui a produit les variables comportementales et temporelles principales, et une seconde phase en Python, qui a complété ces variables avec deux indicateurs supplémentaires.

1. Variables comportementales de paiement

La question que je me suis posée dès le départ était simple : qu'est-ce qui prédit le mieux qu'un client va être en retard le mois prochain ? La réponse, je l'ai trouvée dans son historique récent de paiement. Un client qui était en retard le mois dernier a beaucoup plus de chances de l'être encore ce mois-ci. C'est ce qu'on appelle la persistance des comportements, et c'est le principe sur lequel reposent les quatre variables que j'ai construites. La variable **retard_mois_prec**, elle vaut 1 si le client était en retard le mois précédent, 0 sinon. La variable **nb_retards_3m** correspond au nombre de mois en retard sur trois mois, La variable **taux_retard_cumul,** mesure la proportion de mois en retard depuis le début du contrat, Enfin, le **ratio_redevance,** compare les montants payés aux montants dus.

Ces quatre variables ont toutes été calculées avec un décalage d'un mois pour éviter d'utiliser des informations du mois en cours dans la prédiction, ce qu'on appelle la fuite d'information.

2. Variables de consommation

Le comportement de consommation d'énergie constitue un signal indirect mais précieux sur la situation financière et l'engagement du client vis-à-vis du programme. Trois variables de consommation ont été construites :

- **rechargement_moy_3m :** moyenne mobile du nombre de rechargements sur les trois derniers mois.
- **kwh_moy_3m :** fait la moyenne mobile de la quantité d'énergie achetée sur les trois derniers mois.
- **montant_recharge_prec :** montant total recharge le mois précèdent. Il capture la dernière information disponible sur la capacite financière du client a s'approvisionner en énergie.

3. Variables temporelles

Trois variables temporelles ont été intégrées pour permettre au modèle de tenir compte de la position du client dans son cycle de vie au sein du programme :

- **mois_rang :** rang chronologique du mois observe pour ce client (1 = premier mois d'observation). Il permet de distinguer les nouveaux abonnes des clients anciens, dont les comportements de paiement sont généralement plus stables.
- **Mois :** mois calendaire de l'observation (1 à 12), permettant de capturer d'éventuelles saisonnalités dans les comportements de paiement liées aux cycles de revenus des ménages.

III. PRÉPARATION DES DONNÉES

1. Nettoyage et traitement des valeurs manquantes

Les variables issues des tables ACHATENERGIE et REGLEMENT contiennent des valeurs manquantes, correspondant généralement à des mois sans recharge ou sans paiement direct. Dans ces cas, les valeurs manquantes ont été remplacées par zéro, afin de traduire l'absence d'opération sur la période concernée.

Pour les variables catégorielles (OffreId, RegionId et DirectionId), certaines valeurs manquaient également, probablement en raison d'enregistrements incomplets dans le système. Afin de conserver ces observations, une modalité « INCONNU » a été créée pour intégrer ces cas dans l'analyse tout en indiquant l'absence d'information.

2. Encodage des variables catégorielles

Les variables OffreId, RegionId et DirectionId posaient un problème classique en Machine Learning : ce sont des variables textuelles, et les algorithmes ne savent pas travailler directement avec du texte. Il fallait donc les convertir en nombres. J'ai utilisé l'encodage label, qui consiste simplement à attribuer un code entier à chaque modalité. Cette opération a été faite en R lors de la préparation du jeu d'entraînement. L'important ensuite, c'était de reproduire exactement le même encodage sur les données de validation pour que le modèle retrouve ses repères.

3. Normalisation des variables quantitatives

La normalisation des variables quantitatives vise à ajuster les valeurs de chaque variable pour qu'elles se situent dans une plage spécifique, généralement entre 0 et 1. Cette technique est particulièrement utile lorsque les variables présentent des plages de valeurs différentes et que vous souhaitez les ramener à une échelle commune. Cela peut faciliter la comparaison des variables et aider à éviter que certaines variables ne dominent ou ne biaisent les résultats d'une analyse, ce qui peut être avantageux dans certaines applications, notamment dans les algorithmes d'apprentissage automatique qui sont sensibles à l'échelle des variables. Cette technique de normalisation a donc été utilisé sur l'ensemble de nos variables quantitatives.

IV. SÉLECTION DES VARIABLES

L'identification des variables peu liées à la variable cible permet d'écarter les caractéristiques inutiles. Cela contribue à simplifier le modèle, à améliorer sa capacité de généralisation et à réduire le temps d'entraînement.

La sélection des variables repose sur quatre approches l'analyse exploratoire des données **(EDA), le test de Kruskal-Wallis, le test du Chi-deux (χ^2),** ainsi que des méthodes de **forward et backward.**

1. Analyse Exploratoire

L'EDA nous a permis de découvrir la réalité du portefeuille PEPT : comment les variables sont distribuées, quels clients présentent des comportements atypiques, quelles colonnes contiennent des valeurs manquantes et surtout quelles relations existent entre le comportement de rechargement et le statut de paiement.

2. Test de Kruskal-Wallis

Le test de Kruskal-Wallis est un test non paramétrique utilisé comme alternative à l'ANOVA lorsque l'hypothèse de normalité n'est pas vérifiée. Il permet de comparer la distribution d'une variable continue entre plusieurs groupes. Dans notre cas, Une variable est retenue si la p-value est inférieure à 0,05. Le test a été appliqué à l'ensemble des variables continues afin d'identifier celles dont la distribution diffère significativement selon la variable cible.

3. Test du Chi-deux (χ^2)

a) Principe

Le test du Chi-deux (χ^2) est un test statistique permettant d'évaluer l'indépendance entre deux variables catégorielles. Dans notre contexte, il est utilisé pour vérifier si une variable qualitative est associée à la variable cible.

b) Hypothèses

- **H_0 :** La variable catégorielle est indépendante de la variable cible.
- **H_1 :** il existe une association significative entre les deux variables.

c) Décision

Une variable catégorielle est retenue si la p-value est inférieure à $\boldsymbol{\alpha = 0,05}$. Ce test a été appliqué à l'ensemble des variables qualitatives et binaires du jeu de données.

4. Sélection par les méthodes de Backward et Forward

a) Méthode Forward (ascendante)

La méthode **forward** part d'un modèle avec aucune variable et ajoute à chaque étape la variable qui améliore le plus le critère d'information. L'algorithme s'arrête lorsqu'aucune variable supplémentaire ne permet d'améliorer significativement le modèle.

b) Méthode Backward (descendante)

La méthode backward consiste à partir d'un modèle contenant toutes les variables candidates, puis à supprimer progressivement celles qui apportent le moins d'information.

À l'issue de cette sélection multi-méthodes, 19 variables ont été retenues pour l'entraînement des modèles

PARTIE IV : MODÉLISATION ET PRÉSENTATION DES RESULTATS

Cette partie présente la démarche de modélisation mise en œuvre pour construire le modèle prédictif du comportement de paiement des clients PEPT. Après avoir comparé trois algorithmes de classification, nous exposons les résultats obtenus sur le jeu de test ainsi que les prédictions produites sur le portefeuille actif. L'ensemble de ces éléments constitue le cœur du livrable opérationnel remis à ALC.

CHAPITRE 1 : CONSTRUCTION DU MODELE

Après l'exploration et le traitement des données, nous abordons la construction de notre outil d'aide à la décision. Cependant, la distribution des données est déséquilibrée. Nous utilisons donc deux approches pour résoudre ce problème.

- Créer un modèle à partir des données déséquilibrées
- Créer un modèle à partir des données équilibrées par une Méthode qui sera détaillées dans la suite.

I. TECHNIQUE DE PARTITIONNEMENT DE DONNEES

1- repartition des donnees en train-test

Pour évaluer la performance de notre modèle, nous avons découpé les données en deux ensembles : un ensemble d'apprentissage et un ensemble de test. Nous avons réservé 80 % des données pour l'apprentissage et 20 % pour le test.

2-Validation Croisée

La validation croisée est une méthode d'évaluation des modèles de machine learning. Elle consiste à diviser les données en plusieurs blocs, puis à entraîner le modèle sur une partie des données et à le tester sur la partie restante. Deux approches classiques existent à savoir :

- La validation croisée de type ***Holdout*** consiste à découper les données en un **échantillon d'apprentissage** $(X_i, Y_i)_{i \leq \ell}$ de taille ℓ, représentant de 60 % à 90 % de l'échantillon total, destiné à construire le prédicteur et un **échantillon de validation** $(X_i, Y_i)_{i=\ell+1,\ldots,n}$ destiné à tester la capacité prédictive du modèle construit.

- La validation croisée de type ***K-fold*** consiste à diviser l'échantillon en **K sous-échantillons** de taille approximativement égale et s électionner un des K blocs comme **ensemble de validation**, et la réunion des $K-1$ autres comme **ensemble d'apprentissage.**

Il faut noter que dans chaque cas l'erreur de validation est alors calculée sur l'échantillon de validation. Dans notre cas, La K-fold est l'approche que j'ai privilégiée.

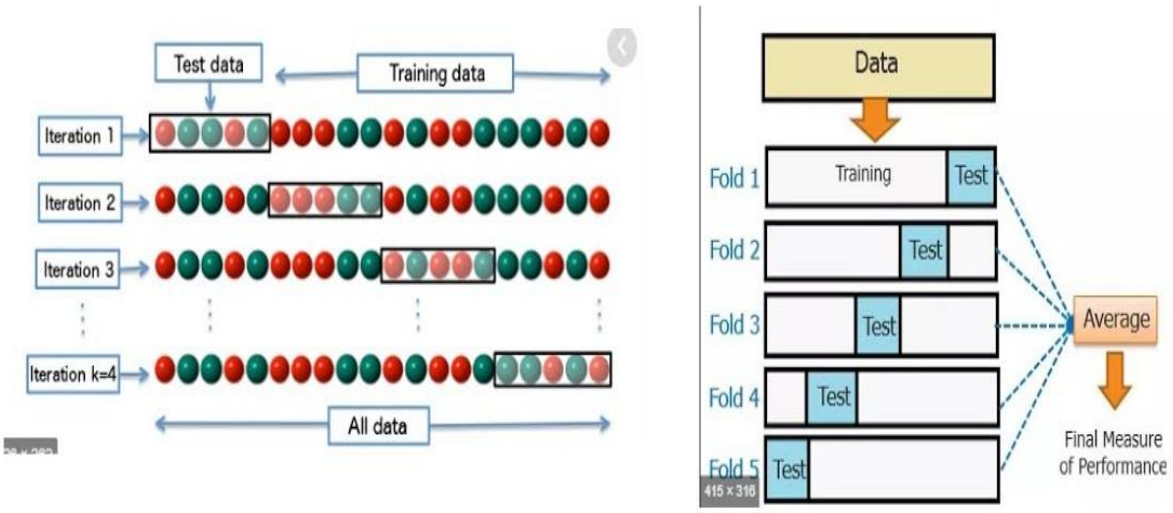


Figure 11: Illustration de la validation croisée

3-Techniques de rééchantillonnage

lorsque les classes d'un ensemble de données ne sont pas représentées de manière égale, il peut être difficile pour les algorithmes de classification binaire supervises de détecter les classes minoritaires, pour palier au problème adaptation des algorithmes standard de ml sur ces données déséquilibrées, il existe deux grandes méthodes que nous utilisons pour rééquilibrer nos données, qui consistent à créer de nouvelles observations dans la classe minoritaire **oversampling** ou à supprimer les individus de la classe majoritaire **undersampling.**

La figure suivante illustre ces méthodes :

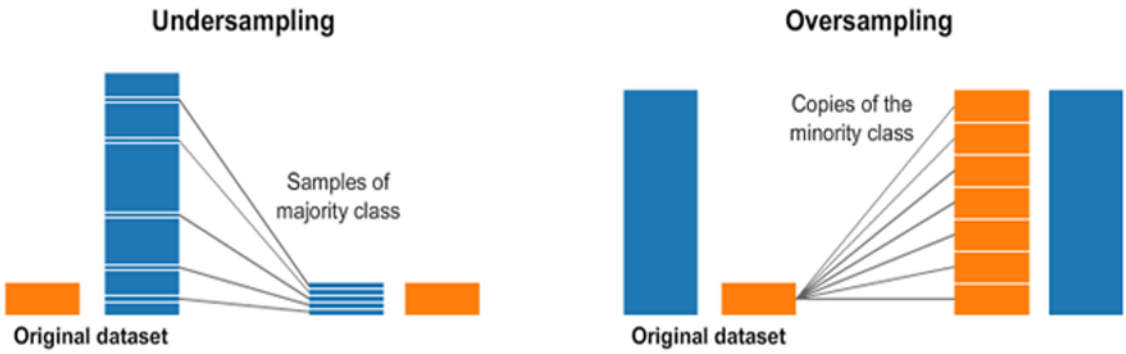


Figure 12: Illustration des techniques de rééchantillonnages

La technique que nous utilisons ici est le **SMOTE**, qui est une technique d'**oversampling** dont le principe consiste à créer de nouvelles observations dans la classe minoritaire en procédant de la manière suivante :

- Trouver la différence entre un point et son plus proche voisin
- Multipliez la différence par un nombre aléatoire entre 0 et 1
- Ajoutez cette différence au point d'origine pour créer un nouvel exemple synthétique
- Continuez avec votre voisin le plus proche jusqu'à ce que vous atteigniez le nombre d'itérations souhaité.

II. LES METRIQUES D'EVALUATION

Un modèle de ML peut sembler performant sur les données d'entraînement et pourtant échouer sur de nouvelles données. C'est précisément pour éviter ce piège que les métriques d'évaluation sont indispensables.

Comme outils d'évaluation des modèles nous utilisons :

1-La matrice de confusion

La matrice de confusion permet de connaître d'une part les différentes erreurs commises par un algorithme de prédiction, mais plus important encore, de connaître les différents types d'erreurs commis. En les analysant, il est possible de déterminer les résultats qui indiquent comment ces erreurs ont eu lieu. Pour calculer une matrice de confusion, on a besoin d'un ensemble de données de test et un autre de validation qui contient les valeurs des résultats obtenus. Chaque colonne du tableau contient une classe prédite par l'algorithme et les lignes des classes réelles.

On classe les résultats en 4 catégories :

- **True Positive (TP)** : la prédiction et la valeur réelle sont positives.
- **True Negative (TN)** : la prédiction et la valeur réelle sont négatives.
- **False Positive (FP)** : la prédiction est positive alors que la valeur réelle est négative.
- **False Negative (FN)** : la prédiction est négative alors que la valeur réelle est positive.

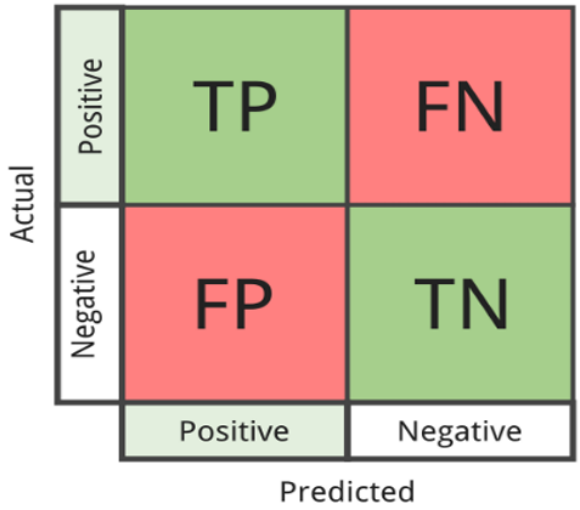


Figure 13: Illustration de Matrice de confusion

En analysant la matrice de confusion, on peut évaluer la capacité du modèle à prédire correctement les classes et identifier les erreurs de classification. Ces informations sont essentielles pour évaluer les performances du modèle et ajuster ses paramètres si nécessaire.

2 - Précision

La précision est le rapport entre les prévisions positives correctes et le nombre total de prévisions positives. Ce paramètre répond donc à la question suivante : sur tous les enregistrements positifs prédits, combien sont réellement positifs ?

$$\textbf{Précision} = VP / (VP + FP)$$

3 - Rappel

Le rappel (ou recall en anglais) est un paramètre qui permet de mesurer le nombre de prévisions positives correctes sur le nombre total de données positives. Il permet de répondre à la question suivante : sur tous les enregistrements positifs, combien ont été correctement prédits ?

$$\textbf{Rappel} = VP / (VP + FN)$$

4 - F1-Score

Le score F1 est une **moyenne harmonique de la précision et du rappel**. Il équivaut au double du produit de ces deux paramètres sur leur somme. Sa valeur est maximale lorsque le rappel et la précision sont équivalents.

$$F1 = (2 \times \text{Précision} \times \text{Rappel}) / (\text{Précision} + \text{Rappel})$$

5 - AUC

L'**AUC (Area Under the Curve)** est une mesure de performance d'un modèle de classification. concrètement, plus l'AUC se rapproche de 1, mieux le modèle distingue un client en retard d'un client à jour. Cette mesure est particulièrement utile dans notre contexte car elle combine deux indicateurs complémentaires :

- **La Sensibilité ou Recall,** qui traduit la capacité du modèle à identifier les mauvais payeurs.
- **La Spécificité** qui traduit la capacité du modèle à détecter l'ensemble des individus négatifs.

Spécificité = VN / (VN + FP)

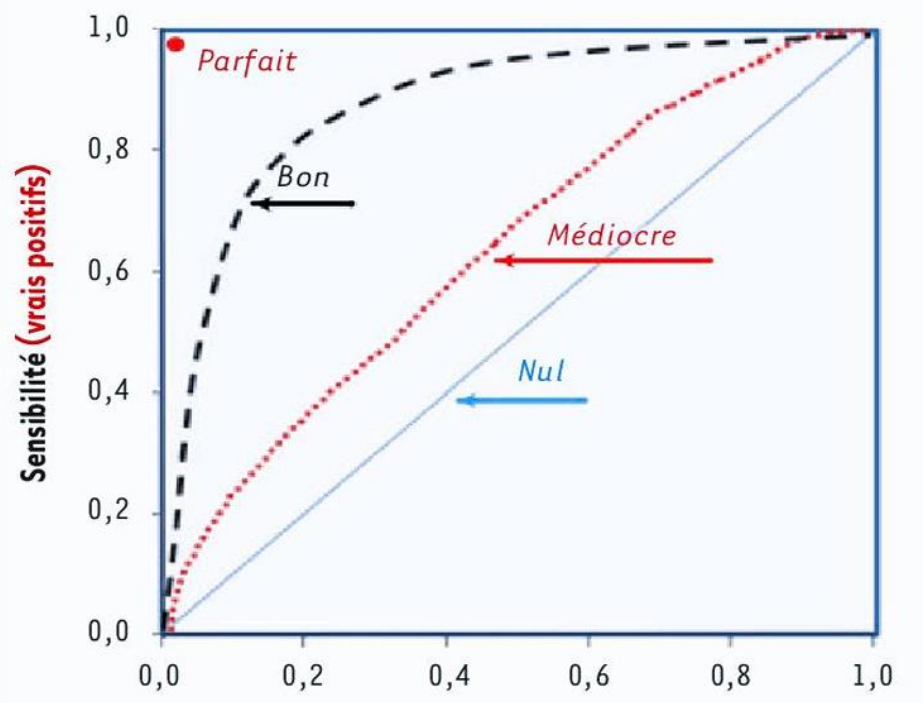


Figure 14: Illustration d'une courbe ROC

CHAPITRE 2 : RESULTATS DES MODELES

I. PROBLEMATIQUE DE CLASSIFICATION

Le problème que nous cherchons à résoudre est un problème de classification binaire supervisée. Pour chaque client et chaque mois, il s'agit de prédire l'appartenance à l'une des deux classes suivantes : la classe 0, correspondant aux clients à jour dans leurs paiements, et la classe 1, correspondant aux clients en retard. La variable cible, construite à partir de la comparaison entre la redevance effectivement payée et la redevance mensuelle normative, a été décalée d'un mois afin de permettre une prédiction prospective.

II. GESTION DU DESEQUILIBRE DES CLASSES

1. Impact du déséquilibre sur la régression logistique sans rééquilibrage

Avant tout rééquilibrage, un premier entrainement de la régression logistique a été réalisé sur les données brutes afin de mesurer l'impact du déséquilibre des classes sur les performances du modèle. Les résultats obtenus sont les suivants :

Tableau 4: Régression logistique sans rééquilibrage des classes

Métrique	En retard (classe 1)	Ajour (classe 0)	Global
Précision	0.82	0.81	0.82
Rappel	0.89	0.72	0.82
F1-score	0.85	0.76	0.81
Accuracy	-	-	81.92 %
AUC-ROC	-	-	0.8913

Ces résultats mettent en évidence un biais caractéristique des modelés entraines sur des données déséquilibrées : le rappel de la classe majoritaire (En retard, 89 %) est nettement supérieur a celui de la classe minoritaire (Ajour, 72 %). Autrement dit, le modèle tend a sur-prédire la classe en retard au détriment de la détection des clients à jour. Ce comportement, bien

qu'il produise une accuracy globale acceptable de 81,92 %, traduit une réelle faiblesse du modèle pour identifier correctement les clients qui honorent leurs engagements.

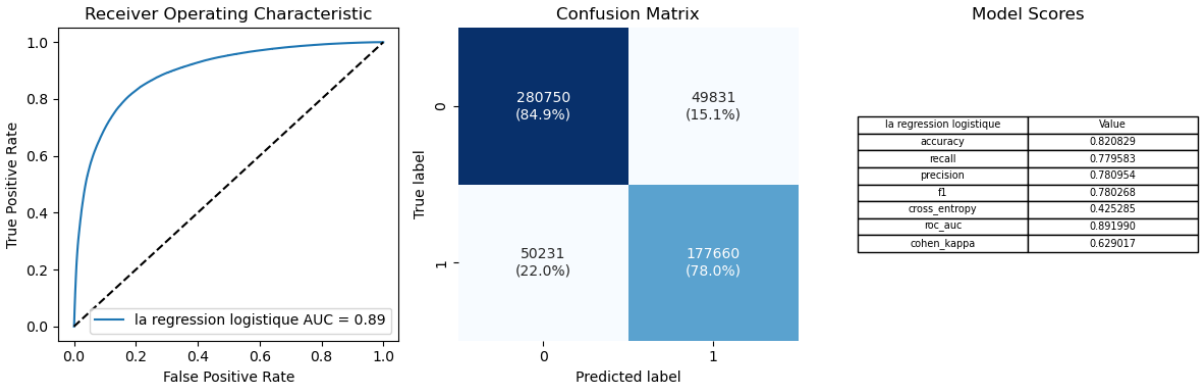
Pour corriger ce biais, les trois modelés ont ensuite été entraines avec une stratégie de rééquilibrage par pondération des classes, qui attribue un poids plus élevé aux observations de la classe minoritaire lors du calcul de la fonction de perte. Les résultats que nous présentons dans les sections suivantes intègrent cette correction.

III. RESULTATS DES MODELES APRES RÉÉQUILIBRAGE

1. Régression Logistique

La régression logistique constitue le modèle de référence de notre étude. Sa simplicité et son interprétabilité en font un point de comparaison indispensable pour évaluer l'apport réel des méthodes plus complexes. Apres rééquilibrage des classes, les résultats obtenus sur le jeu de test sont les suivants :

Tableau 5: Résultats de la Régression Logistique après rééquilibrage

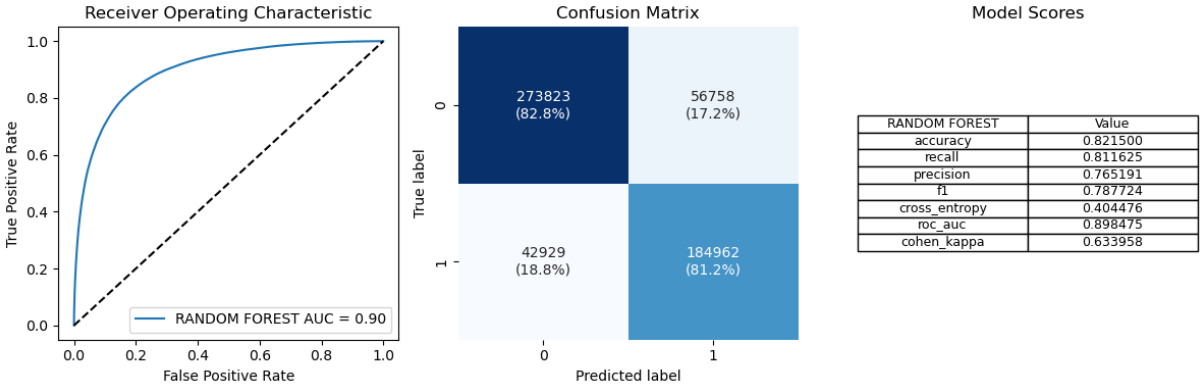


Avec une accuracy de 82,1 % et un AUC-ROC de 0,892, la régression logistique offre des performances solides pour un modèle linéaire. La matrice de confusion révèle que 84,9 % des clients réellement a jour sont correctement identifies (vrais négatifs), tandis que 78,0 % des clients en retard sont bien détectes (vrais positifs). Le F1-score de 0,780 et le coefficient Kappa de Cohen de 0,629 confirment une capacite discriminante satisfaisante, même si la précision sur la classe en retard reste perfectible a 0,781.

2. Forets Aléatoires (Random Forest)

Les forets aléatoires représentent une méthode d'ensemble qui construit plusieurs centaines d'arbres de décision indépendants et agrègent leurs prédictions par vote majoritaire. Cette approche réduit significativement la variance du modèle et lui confère une robustesse naturelle face au surapprentissage. Les résultats après rééquilibrage sont les suivants :

Tableau 6: Résultats du modèle Random Forest



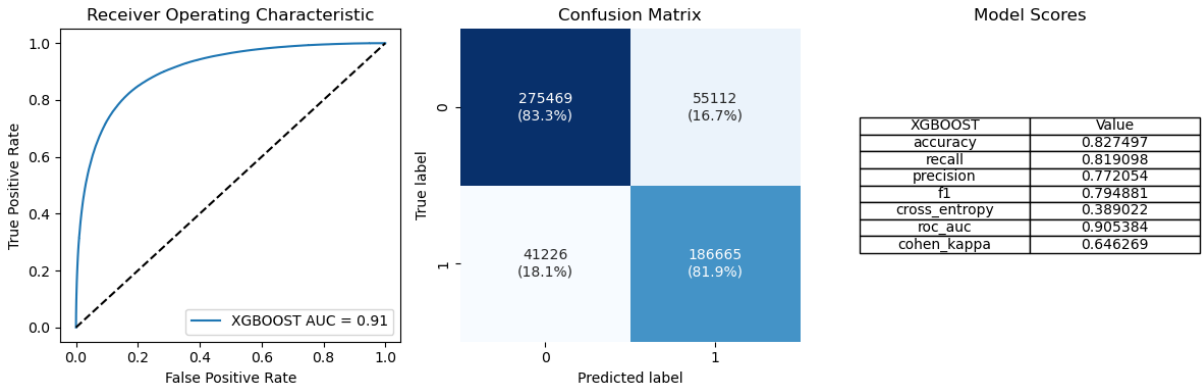
RANDOM FOREST	Value
accuracy	0.821500
recall	0.811625
precision	0.765191
f1	0.787724
cross_entropy	0.404476
roc_auc	0.898475
cohen_kappa	0.633958

Le Random Forest produit une accuracy de 82,2 % et un AUC-ROC de 0,898, légèrement supérieurs a ceux de la régression logistique. La matrice de confusion indique que 82,8 % des clients a jour sont correctement classes et 81,2 % des clients en retard sont bien détectes. Le F1-score de 0,788 et le Kappa de 0,634 témoignent d'une meilleure capacite à équilibrer la détection des deux classes par rapport au modèle linéaire. La précision sur la classe en retard progresse a 0,765, signe que le modèle commet moins de fausses alarmes.

3. XGBoost

XGBoost est un algorithme de Gradient Boosting optimise, qui construit les arbres de manière séquentielle en corrigeant à chaque étape les erreurs résiduelles du modèle précèdent. Il intègre des mécanismes de régularisation qui limitent le surapprentissage et gère nativement les valeurs manquantes. C'est le modèle sur lequel repose notre pipeline de prédiction mensuelle. Les résultats obtenus sont les suivants :

Tableau 7:Résultats du modèle XGBoost



XGBOOST	Value
accuracy	0.827497
recall	0.819098
precision	0.772054
f1	0.794881
cross_entropy	0.389022
roc_auc	0.905384
cohen_kappa	0.646269

XGBoost enregistre les meilleures performances parmi les trois modèles évalues : une accuracy de 82,7 %, un AUC-ROC de 0,905 et un F1-score de 0,795. La matrice de confusion montre que 83,3 % des clients à jour sont correctement identifies et 81,9 % des clients en retard sont bien détectes. Le coefficient Kappa de Cohen de 0,646 traduit un accord substantiel entre les prédictions et les observations réelles. La cross-entropie de 0,389, la plus faible des trois modèles, indique que XGBoost produit des probabilités mieux calibrées, ce qui est particulièrement utile pour le scoring mensuel des clients.

IV. COMPARAISON ET SELECTION DU MODELE OPTIMAL

Le tableau ci-dessous synthétise les performances des trois modèles sur l'ensemble des métriques évaluées :

Tableau 8: Comparaison des performances des trois modèles sur le jeu de test

Métrique	Régression Logistique	Random Forest	XGBoost
Accuracy	82,1 %	82,2 %	82,7 %
Recall	0,780	0,812	0,819
Précision	0,781	0,765	0,772
F1-score	0,780	0,788	0,795
AUC-ROC	0,892	0,898	0,905
Cohen Kappa	0,629	0,634	0,646
Cross-entropie	0,425	0,404	0,389

L'analyse comparative des trois algorithmes fait clairement ressortir XGBoost comme le modèle le plus performant sur l'ensemble des métriques considérées. Il devance le Random Forest et la Régression Logistique sur tous les indicateurs, avec un AUC-ROC de 0,905 qui traduit une excellente capacite à discriminer les clients à jour des clients en retard, indépendamment du seuil de décision retenu. Son F1-score de 0,795 confirme qu'il parvient à maintenir un bon équilibre entre précision et rappel malgré le déséquilibre des classes.

Au-delà de ses performances, XGBoost présente plusieurs avantages supplémentaires. Sa vitesse d'exécution sur des datasets de plusieurs millions d'observations, sa gestion native des valeurs manquantes. C'est donc XGBoost qui a été retenu comme modèle final.

CHAPITRE 3 : PRÉDICTIONS DU MODÈLE

Dans cette section, nous présentons les prédictions produites par le modèle XGBoost retenu à l'issue de la phase de modélisation. Ces prédictions portent sur le comportement de paiement des clients actifs du portefeuille PEPT pour le mois suivant le dernier mois observé.

Afin d'illustrer concrètement le fonctionnement du système de scoring, nous nous sommes restreints à un échantillon de 10 clients titrisés parmi les abonnés actifs du portefeuille. Pour chacun d'eux, le modèle produit deux probabilités complémentaires.

I. SCORES INDIVIDUELS SUR 10 CLIENTS

Tableau 9:Scores individuels XGBoost sur un echantillon de 10 clients PEPT

Reference	Mois	P(A_jour)	P(En_retard)	Prediction
210501005100xy	12	0,9091	0,0909	**A_jour**
210501005101xy	12	0,9849	0,0151	**A_jour**
210501005120xy	12	0,8470	0,1530	**A_jour**
210501005130xy	11	0,0567	0,9433	**En_retard**
210501005140xy	12	0,8699	0,1301	**A_jour**
210501005150xy	12	0,0166	0,9834	**En_retard**
210501005160xy	9	0,0336	0,9664	**En_retard**
210501005170xy	12	0,6285	0,3715	**A_jour**
210501005180xy	10	0,0337	0,9663	**En_retard**
210501005190xy	12	0,3682	0,6318	**En_retard**

II. INTERPRÉTATION DES RÉSULTATS

La lecture de ce tableau appelle plusieurs observations. En premier lieu, on constate que le modèle produit des scores très tranchés pour la majorité des clients : six d'entre eux présentent une probabilité supérieure à 84 % dans leur classe prédite, ce qui traduit un niveau de confiance élevé dans la prédiction. Les clients 210501005101xy et 210501005150xy illustrent les deux extrêmes du spectre : le premier affiche une probabilité d'être à jour de 98,5 %, signe d'un comportement de paiement particulièrement fiable, tandis que le second présente une probabilité d'être en retard de 98,3 %, le classant parmi les profils les plus à risque du portefeuille.

En second lieu, Deux clients dans cet extrait m'ont particulièrement intrigué. Le client 210501005170xy affiche 62,9 % de chance d'être à jour, techniquement on le classe à jour, mais franchement c'est limite. Et le client 210501005190xy est dans la même situation de l'autre côté : 63,2 % de chance d'être en retard. Pour ces deux-là, le modèle hésite. Ce sont des profils qu'on pourrait appeler des clients frontière, un mois ils paient, un mois ils ne paient pas, selon ce qui se passe dans leur vie. C'est précisément ce type de clients qu'il faut surveiller de près chez ALC, car un petit choc peut suffire à les faire basculer durablement dans la catégorie des mauvais payeurs.

Cette granularité dans le scoring est précisément ce qui confère au modèle sa valeur opérationnelle. Plutôt que de produire une classification binaire rigide, il met à disposition d'ALC un outil de priorisation qui permet de concentrer les actions préventives sur les clients présentant les risques les plus élevés, tout en rassurant sur la fiabilité des flux attendus de la part des clients à forte probabilité de paiement.

CONCLUSION

Le travail accompli dans le cadre de ce mémoire, intitulé « Modélisation prédictive des performances financières du programme PEPT pour l'amélioration du processus de titrisation des créances à ALC », a constitué une expérience à la fois exigeante et profondément enrichissante. En nous inscrivant à l'intersection de la finance structurée et de la Data Science, ce projet nous a conduit à mobiliser des compétences techniques variées au service d'une problématique opérationnelle concrète et à fort enjeu financier.

Notre démarche a suivi une progression rigoureuse, articulée autour des phases du processus CRISP-DM. Elle a débuté par une compréhension du programme PEPT et dans le critère financier qui sous-tend les opérations de titrisation menées par ALC. Cette compréhension du métier a été le socle sur lequel l'ensemble des choix techniques ont ensuite reposé. La phase de collecte, réalisée à partir de la base de données d'ALC, a permis de constituer un jeu de données de plus de 2,7 millions d'observations. Nous avons ensuite appliqué des transformations appropriées aux données et avons construit des modèles en utilisant des algorithmes de Machine Learning, en particulier les modèles ensemblistes.

L'objectif principal de ce projet était de construire un modèle capable de prédire si un client allait payer ou non semblait ambitieux. Mais au fil des semaines, le modèle a pris forme et les résultats ont dépassé ce que j'espérais : il classifie les clients à jour et en retard, tout en produisant des scores individuels exploitables sur l'ensemble du portefeuille, répondant ainsi au besoin concret d'ALC dans son processus de titrisation. Cependant, le modèle gagnerait à être amélioré par l'expertise métier des équipes d'ALC, qui connaissent des réalités terrain que les données seules ne capturent pas toujours.

Ce stage m'a surtout appris que la distance entre la théorie et la pratique est bien plus grande qu'on ne l'imagine sur les bancs de l'école. Il a souligné l'importance de la data science dans l'amélioration du processus de titrisation des créances et la prévision des flux financiers.

Cependant, certains moments ont été frustrants. Installer un package python avec les restrictions réseau de l'entreprise, composer avec une mémoire machine limitée, adapter ses scripts aux contraintes du serveur — ce sont des réalités que les cours n'enseignent pas. Mais

c'est précisément en surmontant ces obstacles concrets que j'ai compris ce que signifie vraiment conduire un projet data en entreprise.

BIBLIOGRAPHIE ET WEBOGRAPHIE

- BREIMAN, L. (2001). *Random Forests.* Machine Learning, 45(1), pp. 5-32.
- ANDERSON, R. The Credit Scoring Toolkit: Theory and Practice for Retail Credit Risk
- FRIEDMAN, J. H. (2001). *Greedy Function Approximation: A Gradient Boosting Machine.* The Annals of Statistics, 29(5), pp. 1189-1232.
- https://rouviere.pages.math.cnrs.fr/enseignements/supports/apprentissage_sup.html
- Altman, E. I. (1968). Financial Ratios, Discriminant Analysis and the Prediction of Corporate Bankruptcy. The Journal of Finance, 23(4), 589-609.
- MINISTÈRE DES MINES, DU PÉTROLE ET DE L'ÉNERGIE — CÔTE D'IVOIRE (2014). *Plan National de Développement 2014-2025.*
- UNION ÉCONOMIQUE ET MONÉTAIRE OUEST-AFRICAINE — UEMOA (2010). *Règlement n° 02/2010/CM/UEMOA relatif aux Fonds Communs de Titrisation de Créances et aux Opérations de Titrisation.* Ouagadougou.
- CONSEIL RÉGIONAL DE L'ÉPARGNE PUBLIQUE ET DES MARCHÉS FINANCIERS — CREPMF (2012). *Instruction relative à l'agrément des sociétés de gestion de Fonds Communs de Titrisation de Créances.* Abidjan.
- Africa Link Capital (ALC). Site officiel du Groupe ALC. Disponible sur : https://alc.ci [Consulté en janvier 2026]
- http://dlibrary.univ-boumerdes.dz:8080/bitstream/123456789/8134/1/memoire_fin.pdf
- https://www.xlstat.com/fr/solutions/fonctionnalites/forets-aleatoires-de-classification-et-de-regression
- https://www.jedha.co/formation-ia/matrice-confusion
- https://liora.io/matrice-de-confusion
- https://www.dgenergie.ci/pept/
- Euromoney (2022). *West Africa looks to securitization for social issuance*.
- Chapman, P., Clinton, J., Kerber, R., Khabaza, T., Reinartz, T., Shearer, C., & Wirth, R. (2000). *CRISP-DM 1.0: Step-by-step data mining guide*. SPSS Inc.
- https://www.jedha.co/formation-ia/matrice-confusion
- ALC Titrisation, Documentation interne sur le fonctionnement du FCTC.

ANNEXES

```
/ Calcul redevance payée + target réel
base_2026: update
  redevance_paye: Ponction + RedevancebranchementuniquementFCFA
from base_2026;

base_2026: update
  target_reel: ?[redevance_paye >= RedevanceMensuelleNormative; `A_jour; `En_retard]
from base_2026;

/ Vérification
show "Clients Janvier 2026 : ", string count base_2026;
show select count i by target_reel from base_2026;

/ Export
`:OUTPUT/janvier_2026.csv 0: csv 0! base_2026;
show "Export janvier_2026.csv OK";
```

Figure 15:Application de la règle métier sur kdb/q

Reference <chr>	Mois <dbl>	mois_rang <int>	retard_mois_prec <int>	nb_retards_3m <int>	taux_retard_cumul <dbl>	ratio_redevance <dbl>	target_mois <chr>	target_suivant <chr>
0210501005100	1	1	0	0	0.0000000	0.2647005	En_retard	A_jour
0210501005100	2	2	1	0	1.0000000	1.2705013	A_jour	A_jour
0210501005100	3	3	0	0	0.5000000	2.9491961	A_jour	A_jour
0210501005100	4	4	0	1	0.3333333	3.7656967	A_jour	A_jour
0210501005100	5	5	0	0	0.2500000	3.2896028	A_jour	A_jour
0210501005100	6	6	0	0	0.2000000	1.6636980	A_jour	A_jour
0210501005100	7	7	0	0	0.1666667	1.2856021	A_jour	En_retard
0210501005100	8	8	0	0	0.1428571	0.3780990	En_retard	A_jour
0210501005100	9	9	1	1	0.2500000	1.0586980	A_jour	A_jour
0210501005100	10	10	0	1	0.2222222	1.1645996	A_jour	A_jour

1-10 of 20 rows Previous 1 2 Next

Figure 16 : Aperçu des données

TABLE DES MATIERES

DEDICACE 2
REMERCIEMENTS 3
SOMMAIRE 4
LISTE DES TABLEAUX 7
LISTE DES FIGURES 8
LISTE DES ABREVIATIONS ET SIGLES 9
AVANT-PROPOS 11
RESUME 12
ABSTRACT 13
INTRODUCTION GENERALE 14
PARTIE I : ENVIRONNEMENT DE TRAVAIL 15
CHAPITRE 1 : PRÉSENTATION DE LA STRUCTURE D'ACCUEIL 16
I. PRÉSENTATION DU GROUPE AFRICA LINK CAPITAL (ALC) 16
II. ALC TITRISATION : PREMIÈRE SOCIÉTÉ PRIVÉE DE GESTION DE FCTC EN UEMOA 17
III. POSITIONNEMENT STRATÉGIQUE ET RÔLE DANS LE FINANCEMENT DU DÉVELOPPEMENT 18
CHAPITRE 2 : PRÉSENTATION DU CAHIER DES CHARGES 19
I. CONTEXTE DU PROJET 19
II. OBJECTIF GÉNÉRAL 20
III. OBJECTIFS SPÉCIFIQUES 20
PARTIE II : DÉFINITION DES CONCEPTS 21
CHAPITRE 1 : LE PROGRAMME PEPT ET LA TITRISATION 22
I. FONCTIONNEMENT DU PROGRAMME PEPT 22
II. LA TITRISATION : DÉFINITION, PRINCIPES ET ENJEUX 23
1. Définition 23
2. Principes généraux 23
3. Intérêt de la titrisation pour les différentes parties prenantes 24
III. LA TITRISATION DES FLUX FINANCIERS PEPT À ALC 25
IV. IMPORTANCE DE LA FIABILITÉ DES PAIEMENTS DANS LA TITRISATION 26

CHAPITRE 2 : CONCEPTS DE MACHINE LEARNING 27
I. DÉFINITIONS 27
1. Intelligence Artificielle 27
2. Machine Learning 27
II. LES TYPES D'APPRENTISSAGE EN MACHINE LEARNING 28
Focus : L'apprentissage supervisé 29
III. DESCRIPTION DES MODÈLES DE MACHINE LEARNING UTILISÉS 30
1. La Régression Logistique 30
2. Les Arbres de Décision 31
3. Les Forêts Aléatoires (ou Random Forest en Anglais) 32
4. Le Gradient Boosting et XGBoost 33
4.1. Principe du Gradient Boosting 33
4.2. XGBoost 33
PARTIE III : METHODOLOGIE DE TRAVAIL 34
CHAPITRE 1 : COLLECTE ET DESCRIPTION DES DONNÉES 35
I. SOURCES DE DONNÉES 35
II. DESCRIPTION DES TABLES SOURCES 35
1. Table COMPTEUR 35
2. Table ACHATENERGIE 36
3. Table REGLEMENT 37
III. LOGIQUE MÉTIER DU PROGRAMME PEPT 38
1. La redevance mensuelle normative 38
2. Les modes de recouvrement 38
3. Calcul de la redevance payée et définition du target 38
CHAPITRE 2 : EXPLORATION ET PREPARATION DES DONNEES 40
I. EXPLORATION DES DONNÉES 40
1. Structure générale du dataset 40
2. Distribution de la variable cible 41
II. FEATURE ENGINEERING 41
1. Variables comportementales de paiement 41
2. Variables de consommation 42

3. Variables temporelles 42
III. PRÉPARATION DES DONNÉES 43
1. Nettoyage et traitement des valeurs manquantes 43
2. Encodage des variables catégorielles 43
3. Normalisation des variables quantitatives 43
IV. SÉLECTION DES VARIABLES 44
1. Analyse Exploratoire 44
2. Test de Kruskal-Wallis 44
3. Test du Chi-deux (χ^2) 44
a) Principe 44
b) Hypothèses 44
c) Décision 44
4. Sélection par les méthodes de Backward et Forward 45
a) Méthode Forward (ascendante) 45
b) Méthode Backward (descendante) 45
PARTIE IV : MODÉLISATION ET PRÉSENTATION DES RESULTATS 46
CHAPITRE 1 : CONSTRUCTION DU MODELE 47
I. TECHNIQUE DE PARTITIONNEMENT DE DONNEES 47
1- repartition des donnees en train-test 47
2-Validation Croisée 47
3-Techniques de rééchantillonnage 48
II. LES METRIQUES D'EVALUATION 49
1-La matrice de confusion 49
2 - Précision 50
3 - Rappel 50
4 - F1-Score 50
5 - AUC 51
CHAPITRE 2 : RESULTATS DES MODELES 52
I. PROBLEMATIQUE DE CLASSIFICATION 52
II. GESTION DU DESEQUILIBRE DES CLASSES 52
1. Impact du déséquilibre sur la régression logistique sans rééquilibrage 52

III. RESULTATS DES MODELES APRES RÉÉQUILIBRAGE 53
1. Régression Logistique 53
2. Forets Aléatoires (Random Forest) 54
3. XGBoost 54
IV. COMPARAISON ET SELECTION DU MODELE OPTIMAL 56
CHAPITRE 3 : PRÉDICTIONS DU MODÈLE 57
I. SCORES INDIVIDUELS SUR 10 CLIENTS 57
II. INTERPRÉTATION DES RÉSULTATS 58
CONCLUSION 59
BIBLIOGRAPHIE ET WEBOGRAPHIE 61
ANNEXES 62
TABLE DES MATIERES 63